# RETROALIMENTACIÓN ACADÉMICA
# GRUPO 1 – TELCO CUSTOMER CHURN

Taller C2S1 | Continuidad de limpieza, EDA, análisis univariado y bivariado

Estudiantes: Anny Daiana Trujillo Ortega y Carlos Eduardo Valencia Núñez.

Entregas contrastadas: informe del primer taller (S4_G1.pdf), notebook actual "Taller_EDA_Telco_Trujillo_Valencia (3).ipynb", enunciados docentes y base pedagógica Telco Churn.

## 1. Calificación según la rúbrica unificada

| Criterio | Peso | Nota | Aporte |
|---|---|---|---|
| **Limpieza y preparación de datos** | 30 % | 3,75 | 1,125 |
| **Exploración general (EDA)** | 20 % | 4,25 | 0,850 |
| **Análisis univariado** | 20 % | 3,25 | 0,650 |
| **Análisis bivariado** | 20 % | 4,50 | 0,900 |
| **Perfil de cliente** | 10 % | 4,75 | 0,475 |
| **CALIFICACIÓN FINAL** | 100 % | | 4,00 / 5,00 |

La calificación ponderada es 4,00/5,00. Se reconoce el progreso frente al taller anterior, especialmente la ampliación de la exploración, las comparaciones entre variables y la comprobación del perfil de abandono. Se mantienen las observaciones sobre limpieza e interpretación estadística; no se exige entrenamiento de modelos.

## 2. Continuidad frente al taller anterior

La primera retroalimentación consignó 79/100 (4,0/5,0 en su presentación) y destacó la detección de 35 duplicados, el uso de copy(), la normalización de categorías y la matriz de decisiones. Señaló dos asuntos por fortalecer: distinguir dtype de tipo analítico y, especialmente, hacer coincidir las explicaciones de describe() con sus valores reales.

La entrega actual amplía el análisis con comparaciones frente a Churn, cruces de características y un perfil comprobado. Sin embargo, mantiene interpretaciones numéricas no reconciliadas y contiene un fallo en la limpieza de la etiqueta Churn que es necesario corregir.

## 3. Limpieza y preparación de datos – 3,75/5,00

Fortalezas. Identifica 2.535 registros y 21 columnas, confirma 35 filas duplicadas y 35 identificadores repetidos, elimina las copias y comprueba que no quedan duplicados. Convierte TotalCharges a numérica, normaliza etiquetas de texto, revisa valores fuera de dominio e imputa variables numéricas y categóricas con explicaciones.

Hallazgo crítico. El procedimiento df_clean[col].astype(str).str.strip() convierte los NaN originales de las columnas de texto en la cadena literal “nan”. Por ello, dropna(subset=[“Churn”]) ya no elimina las ocho etiquetas desconocidas. El notebook reporta 2.500 filas limpias y cero nulos, pero solo 2.492 tienen Churn válido para comparaciones con la respuesta. Esas ocho filas se convierten en NaN cuando se mapea Churn a 1/0, sin depuración explícita ni reporte de denominadores.

Mejora concreta. Normalizar con operaciones que preserven nulos, validar Churn contra {Yes, No}, separar o excluir de los análisis dependientes de Churn las etiquetas no recuperables y volver a comprobar totales. Documentar cuánto cambia cada tabla, tasa y perfil.

## 4. Exploración general (EDA) – 4,25/5,00

La organización del notebook es clara: reconocimiento, análisis de calidad, distribuciones categóricas y numéricas, tabla de decisiones y características candidatas. Se utilizan value_counts(), porcentajes, histogramas y estadísticas descriptivas. Esta secuencia responde al objetivo de comprender la base antes de extraer conclusiones de negocio.

No obstante, parte del diccionario se presenta con tipos de pandas en lugar de tipos analíticos; la fuente documental no aparece suficientemente acreditada en el propio cuaderno. La matriz de decisiones se elaboró antes de incorporar las nuevas comparaciones con Churn y merece actualizarse a la luz del análisis bivariado. Algunas conclusiones usan expresiones predictivas o causales que no están justificadas por la exploración.

## 5. Análisis univariado – 3,25/5,00

El grupo estudia por separado categorías y variables numéricas; examina tenure, MonthlyCharges y TotalCharges, describe distribuciones e interpreta gráficos. También informa la tasa general de abandono y realiza análisis por categoría, aunque estos últimos son comparaciones con Churn y conviene distinguirlos de la descripción individual exigida en C2S1.

La debilidad más relevante es la persistencia de errores en las interpretaciones escritas de describe(), problema ya comunicado en el primer taller. Algunos ejemplos contrastados con la transformación del cuaderno son:

| Variable / estadístico | Texto del grupo | Cálculo contrastado |
|---|---|---|
| tenure – media | 32,22 | 29,42 |
| tenure – mediana | 29,00 | 27,00 |
| tenure – desviación | 24,49 | 15,21 |
| MonthlyCharges – media | 65,25 | 65,51 |
| MonthlyCharges – mediana | 70,62 | 72,41 |
| MonthlyCharges – desviación | 29,28 | 25,29 |

Estas discrepancias no son meras diferencias de redondeo. Para atender el aprendizaje pendiente, cada interpretación debe construirse desde la salida vigente de describe(), verificando count, media, mediana, dispersión, cuartiles y extremos después de la limpieza aplicada.

## 6. Análisis bivariado – 4,50/5,00

El trabajo sí desarrolla cruces de características combinadas y Churn: Contract × InternetService, Contract × grupos de tenure, InternetService × TechSupport y Contract × PaymentMethod. Calcula tasas y ofrece gráficos comparativos e interpretaciones contextualizadas. Es un avance claro respecto al taller previo.

Para mejorar la validez del análisis, cada grupo comparado debe incluir el número de clientes válidos y el número de abandonos, no solo su porcentaje. Es necesario excluir explícitamente etiquetas Churn desconocidas y evitar conclusiones causales como que una modalidad contractual por sí sola “reduce” el abandono. Las asociaciones en esta muestra no prueban causalidad.

## 7. Perfil histórico del cliente – 4,75/5,00

El grupo define un segmento mediante tres condiciones verificables: contrato Month-to-month, internet Fiber optic y permanencia de 0 a 12 meses. A diferencia de una caracterización meramente narrativa, utiliza un filtro y presenta un conteo explícito del segmento.

| Indicador | Resultado del notebook |
|---|---|
| Tamaño del segmento | 77 clientes |
| Clientes que abandonaron | 54 |
| Tasa de abandono del segmento | 70,13 % |
| Tasa general calculada | 39,53 % |
| Diferencia | +30,60 puntos porcentuales |

La tasa del segmento es aritméticamente coherente: 54/77 × 100 ≈ 70,13 %. La comparación con el promedio es útil para el negocio. Debe precisarse que el total de

2.500 incluye ocho Churn inválidos; los denominadores pertinentes a la tasa global son los 2.492 casos con respuesta conocida. Además, “mayor riesgo” se interpreta como mayor proporción histórica observada, no como una probabilidad individual predicha ni como evidencia de significación estadística formal.

## 8. Fortalezas, prioridades y orientación pedagógica

### Fortalezas verificadas

Estructura legible; detección y comprobación de duplicados; uso razonado de imputaciones; gráficos y tablas para describir los datos; cruces concretos de características; perfil comprobado con tamaño y abandonos.

### Prioridades de corrección

1) Conservar los valores faltantes al normalizar texto y verificar la validez de Churn. 2) Regenerar y comentar las cifras de describe() de la base efectivamente tratada. 3) Incluir tamaños muestrales y abandonos en cada tabla bivariada. 4) Actualizar la matriz final de candidatas con la evidencia nueva y corregir expresiones causales o predictivas no demostradas.

## 9. Concepto final del docente

El Grupo 1 demuestra una evolución positiva respecto al taller anterior. Además de retomar la preparación de la base Telco Customer Churn, organiza la exploración, presenta distribuciones y desarrolla comparaciones que permiten comprender cómo varía el abandono según las características de los clientes. Su principal avance es que no se limita a describir variables: combina condiciones para identificar un segmento de 77 clientes, de los cuales 54 abandonaron el servicio (70,13 %). Este resultado está respaldado por una comprobación directa y ofrece un punto de partida útil para formular preguntas de negocio sobre la permanencia de clientes.

Sin embargo, la confiabilidad del análisis depende de una limpieza cuidadosa. El cuaderno elimina correctamente 35 registros duplicados, pero una transformación de texto convierte los valores faltantes de Churn en la palabra «nan». Como consecuencia, ocho clientes sin una etiqueta válida permanecen en la base de trabajo. Esta situación no invalida todo el esfuerzo realizado, pero exige verificar que cualquier proporción de abandono utilice exclusivamente clientes con una respuesta Yes o No auténtica. El grupo debe preservar los nulos durante la normalización y comprobar los totales antes de interpretar las tablas.

También persiste una dificultad señalada en el taller anterior: algunas cifras escritas para media, mediana y desviación estándar no coinciden con los resultados calculados

en el notebook. No se trata de un detalle de presentación. Si la explicación dice que la antigüedad promedio de los clientes es distinta de la calculada, la conclusión estadística pierde sustento. La práctica que deben fortalecer es ejecutar el cuaderno de principio a fin y contrastar cada afirmación con la salida vigente del código, particularmente en la interpretación de describe().

La nota de 4,00/5,00 reconoce un trabajo bueno, con avances verificables en EDA, análisis bivariado y construcción del perfil. No significa que las dificultades detectadas estén resueltas. Para alcanzar un desempeño sobresaliente, el grupo debe cerrar la limpieza de Churn, revisar las cifras descriptivas que comunica e incluir las cantidades que respaldan las tasas comparadas. El aprendizaje central de esta etapa es que una conclusión empresarial vale tanto como la calidad de los datos y la coherencia entre cálculo, tabla, gráfico e interpretación.

CALIFICACIÓN FINAL: 4,00 / 5,00