RETROALIMENTACIÓN ACADÉMICA
GRUPO 4 – TELCO CUSTOMER CHURN

Taller C2S1 | Limpieza, EDA, análisis univariado y bivariado

Estudiante: Jhoan Sebastián Ordóñez Campo. Asignatura: Inteligencia de Negocios. Base: Telco Customer Churn (versión pedagógica).

1. Rúbrica ponderada de evaluación

Criterio	Peso	Calificación	Aporte
Limpieza y preparación de datos	30 %	4,50	1,350
Exploración de datos (EDA)	20 %	4,75	0,950
Análisis univariado	20 %	4,75	0,950
Análisis bivariado	20 %	4,75	0,950
Construcción del perfil	10 %	4,75	0,475
CALIFICACIÓN FINAL	100 %		4,68 / 5,00

Nota: la suma ponderada es 4,675, expresada con dos decimales como 4,68/5,00. El criterio se aplica exclusivamente a las actividades de preparación, exploración y análisis; no se exige entrenar modelos.

2. Continuidad con la retroalimentación anterior

En el taller anterior, el estudiante obtuvo 1,30/5,00. Se habían señalado, entre otros aspectos, la ausencia de diccionario de datos y clasificación analítica, la falta de investigación de duplicados, categorías con inconsistencias aún visibles, extremos no examinados, exploración descriptiva limitada y ausencia de matriz final. En la nueva entrega existe una mejora sustancial y verificable: el Notebook ahora incluye contexto, fuentes, identificación de las 21 variables, investigación de registros repetidos, criterios explícitos de limpieza, exploración gráfica, interpretación de describe(), comparaciones con Churn, matriz y perfil comprobado. Esta comparación reconoce el progreso, sin sustituir la evaluación del trabajo actual.

3. Limpieza y preparación de datos — 4,50/5,00

La base empieza con 2.535 registros y 21 columnas. El estudiante identifica 35 filas totalmente duplicadas, investiga sus customerID y retira una copia de cada duplicado:

permanecen 2.500 clientes. Examina tanto los faltantes explícitos como los textos que ocultan ausencias; normaliza variantes categóricas y convierte TotalCharges considerando representaciones monetarias diferentes. Analiza valores fuera de dominio, extremos y contradicciones entre servicios; no los sustituye automáticamente, sino que registra los cambios y deja los casos sin evidencia suficiente como valores faltantes.

Un acierto decisivo es separar la base de 2.500 clientes de las 2.492 observaciones con Churn válido: los ocho registros sin etiqueta no se utilizan en comparaciones ni en perfiles. Esto corrige una dificultad observada en otros trabajos. Como cautela técnica, la regla TotalCharges ≈ tenure × MonthlyCharges es orientativa y no constituye una igualdad obligatoria, pues los cobros históricos pueden variar; las correcciones de extremos deben apoyarse además en la consistencia del dominio. La elección de la categoría más frecuente como referencia de normalización también debe contrastarse con el diccionario para evitar fusionar valores legítimamente distintos.

4. Exploración de datos (EDA) — 4,75/5,00

Reconoce el contexto y documenta un diccionario con fuente; diferencia tipo analítico de dtype y clasifica identificadores, variables categóricas, numéricas y objetivo. Presenta inventarios de niveles, proporciones, gráficos, distribución de Churn, un registro de modificaciones y matriz de decisiones para las 21 columnas. La selección final de candidatas está argumentada y distingue las variables que conviene conservar, transformar o revisar. La claridad del orden permite seguir la secuencia del análisis. Para máxima reproducibilidad, conviene ofrecer una ruta relativa o una alternativa de carga accesible, además de la ruta personalizada a Google Drive.

5. Análisis univariado — 4,75/5,00

El estudio individual de variables incluye frecuencias, porcentajes, barras, histogramas, diagramas de caja, dispersión y lectura del contexto. Se interpretan count, media, mediana, desviación, cuartiles, extremos y asimetría para tenure, MonthlyCharges y TotalCharges; las cifras escritas concuerdan, en términos generales, con las salidas guardadas. La distribución válida de Churn aparece correctamente explicada: 985 abandonos de 2.492 clientes (39,53 %). Se destaca que no se confunde mayor dispersión con capacidad predictiva demostrada. Algunas caracterizaciones de extremos como «casos reales» necesitan formularse como plausibles según la evidencia disponible, no como certezas verificadas externamente.

6. Análisis bivariado — 4,75/5,00

Presenta tablas cruzadas de variables categóricas frente a Churn con denominadores y porcentajes de abandono, así como comparaciones numéricas por condición de abandono y gráficos complementarios. Contrasta los resultados con la tasa general

(39,53 %) y distingue cantidades absolutas de proporciones. Por ejemplo, informa 727 abandonos entre 1.345 clientes con contrato mes a mes (54,1 %) y diferencias por InternetService y PaymentMethod. También estudia relaciones entre explicativas e identifica información potencialmente repetida entre TotalCharges, tenure y MonthlyCharges. La interpretación evita, en su mayoría, convertir asociaciones en causalidad. Expresiones como «cada característica suma riesgo» deben entenderse solo como una tasa observada al agregar filtros, no como efectos independientes o causales.

7. Construcción del perfil — 4,75/5,00

El perfil principal combina contrato mes a mes, fibra óptica y cheque electrónico. La comprobación mediante filtros reúne 188 clientes con Churn válido, de los cuales 130 abandonaron: 69,15 %, frente al 39,53 % de la base válida. La diferencia es cercana a 29,6 puntos porcentuales. El estudiante informa además el grupo restante y una variante de menor tamaño (28 clientes, 24 abandonos, 85,7 %), advirtiendo correctamente que esa variante es demasiado pequeña para convertirla en su perfil principal sin reservas. Es una construcción empírica sólida; corresponde aclarar que se trata de un segmento con abandono alto, no de una regla predictiva validada ni de una demostración de causalidad.

8. Recomendaciones concretas

Mantener el registro reproducible de transformaciones; respaldar la identificación de valores imposibles con el diccionario y no solo con aproximaciones aritméticas; dejar explícito cuándo una conclusión es descriptiva o hipotética; revisar la accesibilidad de la ruta de lectura de datos; y conservar en cada interpretación el denominador y el tamaño de los grupos comparados. Estas acciones perfeccionarían un trabajo que ya resuelve satisfactoriamente las actividades centrales de C2S1.

9. Concepto final del docente

El Grupo 4 evidencia una evolución académica muy importante frente a la primera entrega. Antes predominaba la ejecución parcial de instrucciones de limpieza y el diagnóstico quedaba sin cerrar: no se examinaban adecuadamente los duplicados, los extremos ni el significado de las variables, y faltaban interpretaciones y decisiones documentadas. En esta continuación, el estudiante transforma ese enfoque en un proceso de análisis razonado: investiga cada problema, registra qué cambió, explica por qué conserva valores o los deja pendientes y comprueba que los cálculos sobre abandono se apoyen en etiquetas válidas. El paso de 2.535 registros originales a 2.500 clientes únicos y a 2.492 casos aptos para estudiar Churn está claramente diferenciado, lo que mejora la credibilidad del análisis.

En la etapa exploratoria, el progreso no consiste solo en haber incorporado más gráficos. Ahora las tablas y medidas estadísticas reciben una lectura de negocio, las comparaciones identifican diferencias de abandono entre tipos de contrato, servicio y pago, y los hallazgos culminan en un perfil cuya cantidad y tasa pueden comprobarse directamente en los datos. El segmento de 188 clientes, con 130 abandonos, muestra cómo pasar de observaciones aisladas a una conclusión concreta: en esta base, determinadas combinaciones de características presentan una proporción histórica de abandono claramente superior a la general.

El aspecto por fortalecer es la prudencia de las inferencias. La coherencia aproximada entre cargos, antigüedad y facturación puede señalar registros que requieren revisión, pero no garantiza que un extremo sea erróneo. Asimismo, que un grupo muestre mayor abandono no significa que las características analizadas lo causen ni que el mismo porcentaje se repetirá en nuevos clientes. El estudiante debe distinguir siempre entre evidencia observada, hipótesis explicativa y decisión futura de modelado. En conjunto, el trabajo cumple ampliamente el propósito pedagógico: utilizar limpieza y exploración confiables para fundamentar análisis univariados, bivariados y un perfil verificable, sin anticipar el entrenamiento de modelos. Por estos motivos, la valoración propuesta es 4,68/5,00.