RETROALIMENTACIÓN ACADÉMICA
GRUPO 5 – TELCO CUSTOMER CHURN

Taller C2S1 | Limpieza, EDA y análisis univariado y bivariado

Estudiantes: Julián Alberto Liz Valencia y Juan Manuel Manzano Truque. Archivo revisado: TrabajoFinalMachine.ipynb. Antecedente contrastado: retroalimentación S4_G5.pdf (taller anterior, 2,60/5,00).

1. Rúbrica de evaluación

Criterio	Peso	Nota	Aporte
Limpieza y preparación de datos	30 %	3,25	0,98
Exploración de datos (EDA)	20 %	3,50	0,70
Análisis univariado	20 %	3,25	0,65
Análisis bivariado	20 %	3,25	0,65
Construcción del perfil	10 %	1,75	0,18
CALIFICACIÓN FINAL	100 %		3,15 / 5,00

2. Continuidad del taller anterior

En la evaluación previa (2,60/5,00) se señalaron problemas en la investigación de duplicados, la interpretación de las variables y la coherencia entre decisiones y evidencia. El cuaderno actual muestra avances: cita IBM, contrasta los 35 registros duplicados con customerID, documenta imputaciones y desarrolla nuevas comparaciones con Churn. Es un progreso real, pero no plenamente consolidado.

3. Limpieza y preparación de datos – 3,25/5,00

La primera secuencia elimina 35 duplicados y ocho registros sin Churn; obtiene 2.492 filas, imputa Partner y PaymentMethod como Unknown y utiliza medianas para cargos faltantes. Estas actuaciones constituyen una mejora respecto al taller anterior.

El problema principal aparece en la continuidad técnica: más adelante se observan salidas de data.info() con 2.535 filas, 35 duplicados incorporados y faltantes originales. Es decir, las salidas guardadas del análisis posterior no corresponden a la base limpia de 2.492 filas. Además, Churn contiene Yes, No, yes, NO con espacio y nulos; el mapeo mostrado no normaliza NO con espacio y deja observaciones sin etiqueta

binaria. Debe generarse una sola base depurada, normalizar valores válidos y repetir todos los cálculos desde ella.

Persisten valores imposibles descritos por los autores, por ejemplo antigüedad de -3 meses y cargos mensuales de -15. Es correcto identificarlos, pero resulta insuficiente dejarlos pendientes si van a sustentar conclusiones finales. Deben documentar su tratamiento o excluirlos de las comparaciones afectadas.

4. Exploración de datos (EDA) – 3,50/5,00

El notebook incluye diccionario, clasificación, estadísticas descriptivas, frecuencias, gráficos y matriz de decisiones. Se reconoce una estructura metodológica amplia. Sin embargo, la exploración se mezcla con procedimientos que usan distintas versiones de data, lo cual impide tener una población estable para contrastar resultados. La matriz debe actualizarse después de la limpieza definitiva e incorporar las evidencias bivariadas relevantes.

5. Análisis univariado – 3,25/5,00

Presenta describe(), histogramas y boxplots de tenure, MonthlyCharges y TotalCharges, además de distribuciones categóricas y tasas de abandono por segmentos. Se observa esfuerzo por interpretar la información en lenguaje empresarial.

Hay dos problemas de razonamiento: afirmar que las variables numéricas «no presentan diferencias» y «no son predictivas» es más concluyente de lo que permiten los gráficos; y después atribuir cambios de abandono a vencimientos de contratos o sensibilidad al precio sin pruebas específicas. Las observaciones deben indicar qué muestra cada gráfico, cuántos registros respalda y qué no se puede concluir. Los estadísticos redactados deben verificarse contra una nueva ejecución completa.

6. Análisis bivariado – 3,25/5,00

Se construyen tasas de Churn para combinaciones Contract–tenure_rango, InternetService–tenure_rango y PaymentMethod–tenure_rango. Es una ampliación pertinente que aporta información descriptiva y contextual. La principal limitación es que la función agrupa y visualiza promedios, pero no acompaña sistemáticamente cada combinación con su número de clientes ni con el conteo de abandonos; por ello, tasas elevadas de subgrupos pequeños pueden interpretarse exageradamente. Tampoco queda demostrado que los cruces se realizaron sobre la base ya depurada.

7. Construcción del perfil – 1,75/5,00

Los estudiantes describen un perfil plausible: contrato mes a mes, menor antigüedad, fibra óptica, ausencia de soporte técnico y cheque electrónico. No obstante, se presenta como síntesis narrativa sin ejecutar un filtro conjunto que permita comprobar cuántos clientes cumplen simultáneamente esas condiciones, cuántos tienen Churn = Yes y cuál es la tasa de abandono. Tampoco se comprueba frente a la tasa general con un denominador válido. Por consiguiente, hay una propuesta conceptual, pero falta la verificación empírica exigida.

8. Recomendaciones prioritarias

1) Ejecutar desde cero el notebook, utilizando una sola variable de trabajo limpia y mostrando al final conteos de filas, IDs únicos, faltantes y etiquetas válidas. 2) Corregir inconsistencias y valores imposibles antes de interpretar. 3) Acompañar cada cruce con tamaño del grupo, número de abandonos y tasa calculada. 4) Verificar el perfil mediante un único filtro de todas sus condiciones. 5) Redactar conclusiones asociativas, no causales, y comprobar cada cifra contra la salida final.

9. Concepto final del docente

El Grupo 5 presenta una evolución apreciable frente al taller anterior. La nueva entrega contiene un diccionario más fundamentado, mejora la identificación de registros duplicados y avanza hasta comparaciones entre características de los clientes y su abandono. Estos elementos indican que comprendieron el recorrido pedagógico propuesto: preparar los datos, explorarlos y buscar patrones útiles para el negocio.

Sin embargo, el punto crítico no es la cantidad de gráficos o de código escrito, sino la continuidad de los datos sobre los que se obtienen las conclusiones. Aunque la limpieza inicial deja 2.492 clientes, otras salidas del mismo cuaderno vuelven a mostrar 2.535 registros y problemas de calidad que ya debían estar resueltos. Cuando se mezclan resultados de versiones distintas de la base, las tasas y las interpretaciones dejan de ser plenamente comparables. Antes de describir el comportamiento de los clientes, es necesario saber con certeza qué población se está analizando.

El análisis bivariado es un avance, porque explora diferencias de abandono al combinar condiciones comerciales y de permanencia. No obstante, las proporciones deben respaldarse con conteos y la interpretación debe distinguir una asociación observada de una causa demostrada. Asimismo, la caracterización final del cliente no basta como perfil validado: debe probarse sobre los registros y expresar número de clientes, número de abandonos y porcentaje, frente a la tasa general.

La nota de 3,15/5,00 reconoce el progreso en exploración y comparaciones, pero refleja que todavía falta asegurar la reproducibilidad de la limpieza y verificar cuantitativamente el perfil. La mejora decisiva para el grupo es trabajar con una sola base depurada y comprobar que cada explicación escrita procede directamente del resultado calculado.