RETROALIMENTACIÓN ACADÉMICA
GRUPO 7 – TELCO CUSTOMER CHURN

Taller C2S1: continuidad de la limpieza, EDA, análisis univariado, bivariado y perfil del cliente

Integrantes: María José Barrios Ortega y Heitan Santiago Manquillo Tose

Base común: Telco_Churn_Taller_Datos_Sucios.csv | Escala: 1,00 a 5,00

1. Rúbrica y calificación

Criterio	Peso	Nota	Aporte
Limpieza y preparación	30 %	3,75	1,125
Exploración general (EDA)	20 %	4,00	0,800
Análisis univariado	20 %	3,00	0,600
Análisis bivariado	20 %	4,00	0,800
Construcción del perfil	10 %	2,50	0,250
TOTAL	100 %		3,58 / 5,00

Cálculo: 1,125 + 0,800 + 0,600 + 0,800 + 0,250 = 3,575; redondeado a dos decimales: 3,58.

2. Continuidad respecto al taller anterior

La evaluación anterior (S4_G7) registró 3,70/5,00. Destacó el diccionario y la investigación de duplicados; señaló una falla lógica en la preparación, interpretaciones numéricas que no coincidían con las salidas y decisiones de la matriz que no siempre se aplicaban. La nueva entrega incorpora explícitamente comparaciones con Churn, visualizaciones adicionales y un filtro para el perfil. Sin embargo, permanecen problemas esenciales de validación: valores de Churn convertidos en texto y explicaciones que no corresponden a la salida del código.

3. Limpieza y preparación de datos — 3,75/5,00

Fortalezas. Se parte de 2.535 filas y 21 columnas; se identifican 35 duplicados exactos y 35 customerID repetidos, se eliminan las copias y se documenta la decisión. Se normalizan categorías, se convierten los cargos totales a valores numéricos y se tratan valores fuera de rango en variables como tenure y MonthlyCharges.

Dificultad principal. La instrucción df_clean[col].astype(str).str.strip() convierte ausencias reales en la cadena «nan». Posteriormente dropna(subset=[«Churn»]) no elimina esas

ocho etiquetas ausentes convertidas en texto. Por ello la salida de 2.500 filas con cero nulos no demuestra que las 2.500 tengan Churn válido: hay 2.492 respuestas válidas y ocho cadenas no válidas. La tasa general calculada como (Churn == «Yes»).mean() emplea 2.500 como denominador y muestra 39,40 %, en lugar de calcular la tasa sobre los casos con respuesta válida (aproximadamente 39,53 %).

Otras precisiones. El texto afirma que las ocho etiquetas se eliminaron, pero la salida registra 2.500 filas. También afirma que TotalCharges se imputa con mediana, cuando el código usa tenure × MonthlyCharges. Esta fórmula puede ser una aproximación, pero no reconstruye automáticamente un cobro histórico real y debe justificarse o dejarse como estimación.

4. Exploración general (EDA) — 4,00/5,00

El cuaderno presenta reconocimiento estructural, frecuencias de variables categóricas, análisis de variables numéricas, representaciones gráficas y matrices de decisión. El trabajo está organizado en secciones y relaciona los hallazgos con el negocio. Conviene revisar de nuevo las decisiones de la matriz final, distinguir claramente identificadores de variables categóricas y asegurar que la población depurada usada en tablas, gráficos y conclusiones sea la misma.

5. Análisis univariado — 3,00/5,00

Se incorporan histogramas, diagramas de caja y describe() para tenure, MonthlyCharges y TotalCharges. Los gráficos y el código son pertinentes, pero reaparece una dificultad advertida en el taller anterior: los comentarios estadísticos mezclan cifras de diferentes versiones de la muestra. En la salida guardada, tenure tiene media 29,42 meses, mediana 27,00 y desviación estándar 15,21; sin embargo, una explicación previa indica media 32,22, mediana 29,00 y desviación 24,49, y otra expone valores alternativos en el mismo párrafo. El análisis debe presentar un único conjunto de cifras reproducibles que corresponda a la versión de datos realmente utilizada.

Para cada variable conviene explicar count, media, mediana, desviación, cuartiles, extremos y posible asimetría sin trasladar valores de otro dataset o ejecución. Un error de interpretación estadística no se corrige agregando más gráficos: se corrige cotejando cada texto con la tabla calculada.

6. Análisis bivariado — 4,00/5,00

El grupo compara variables numéricas con Churn mediante diagramas de caja y calcula tasas por contrato, servicio de internet, método de pago, soporte técnico y otras

categorías; también estudia rangos de antigüedad y cargos. Esto responde sustancialmente al objetivo de analizar asociaciones. Para fortalecerlo, cada tasa debe acompañarse del número de casos con Churn válido, especialmente cuando los segmentos son pequeños. Además, algunas interpretaciones proponen mecanismos causales —por ejemplo, que un método de pago genere retención o que la falta de soporte produzca cancelación— que no pueden inferirse directamente de comparaciones observacionales.

7. Construcción y verificación del perfil — 2,50/5,00

El grupo define un perfil con cuatro condiciones: contrato mes a mes, fibra óptica, cheque electrónico y ausencia de seguridad en línea. Es positivo que aplique un filtro conjunto para comprobarlo; la dificultad aparece al redactar cifras diferentes de las obtenidas en el código.

Comparación entre la salida del Colab y la interpretación escrita:

Indicador	Resultado del código	Conclusión escrita
Clientes del perfil	136	278
Clientes que abandonaron	91	172
Tasa de abandono del perfil	66,91 %	61,87 %
Tasa general de abandono válida	39,53 %	26,60 %

Interpretación: el filtro comprueba 136 clientes, de los cuales 91 abandonaron (66,91 %). Esta tasa supera en 27,38 puntos porcentuales la tasa general válida (39,53 %). La conclusión menciona otro tamaño de grupo y otras tasas sin una salida que las sustente. Deben ejecutar nuevamente el filtro y actualizar el texto con sus resultados. Por esta discrepancia en el resultado central del taller se mantiene la nota de 2,50/5,00 en este criterio.

8. Recomendaciones puntuales

Primero, normalizar cadenas preservando los nulos reales y validar Churn únicamente contra Yes/No antes de calcular tasas; registrar 2.492 observaciones utilizables para comparaciones. Segundo, ejecutar todo el cuaderno desde el comienzo y actualizar cada interpretación con el describe() y las tablas de esa ejecución. Tercero, anexar tamaños de grupo a las tasas bivariadas y describir asociaciones sin afirmar causalidad. Cuarto, sustituir el perfil escrito por los 136 clientes, 91 abandonos y 66,91 % que arroja el filtro, o modificar y volver a ejecutar el filtro si el objetivo es otro perfil.

9. Concepto final del docente

El Grupo 7 evidencia una continuación real del trabajo previo: organiza el análisis, explora las variables y logra relacionar características del cliente con el abandono del servicio. Merece especial reconocimiento que haya construido un filtro que reúne varias condiciones y calculado directamente el número de clientes y la proporción que abandonó. Este avance muestra comprensión de que un perfil de negocio debe poder verificarse con datos, no limitarse a una descripción intuitiva.

La principal dificultad no es la ausencia de técnicas, sino la falta de consistencia entre etapas del análisis. La normalización convierte algunos faltantes de Churn en texto, de modo que el cuaderno presenta como depurada una población que todavía contiene ocho etiquetas inválidas. A ello se suma la repetición de cifras de describe() que no corresponden a la salida actual. El problema se hace más visible en la conclusión del perfil: el código encuentra 136 clientes y 91 abandonos, pero el texto anuncia 278 y 172. Ante esas diferencias, el lector no puede saber qué resultado sustenta realmente la decisión empresarial.

La prioridad formativa es desarrollar una rutina de verificación: limpiar y comprobar categorías válidas, ejecutar el notebook completo, revisar la población usada en cada operación y redactar las conclusiones exclusivamente a partir de sus salidas. Con estas correcciones, el grupo podría convertir un análisis técnicamente amplio en evidencia fiable para la toma de decisiones. La calificación de 3,58/5,00 reconoce el avance en EDA y análisis bivariado, y refleja las debilidades todavía presentes en limpieza, interpretación univariada y verificación final del perfil.