RETROALIMENTACIÓN ACADÉMICA
GRUPO 8 – TELCO CUSTOMER CHURN

Taller C2S1 · Limpieza, EDA, análisis univariado, bivariado y perfil

Estudiante: Miguel Alejandro Yela Vega. Base: Telco Customer Churn. Entrega revisada: C2S1 - Análisis Univariado y Bivariado.ipynb. Antecedente: S4_G8.pdf (taller anterior).

1. Rúbrica ponderada y resultado

Criterio	Peso	Nota	Aporte
Limpieza y preparación	30 %	3,50	1,050
Exploración de datos (EDA)	20 %	4,75	0,950
Análisis univariado	20 %	3,75	0,750
Análisis bivariado	20 %	4,00	0,800
Construcción del perfil	10 %	4,50	0,450
CALIFICACIÓN FINAL	100 %		4,00 / 5,00

Criterio de valoración: se reconoce la mejora frente al taller de limpieza anterior, sin dejar de evaluar la consistencia técnica de las transformaciones, las estadísticas y la interpretación de negocio. No se exige entrenamiento de modelos.

2. Continuidad respecto al taller anterior

La retroalimentación previa otorgó 2,30/5,00 e identificó como principal dificultad que varios problemas de calidad se detectaban, pero no se corregían o comprobaban. El nuevo cuaderno muestra un progreso claro: incorpora transformaciones ejecutadas, verificación final, tablas cruzadas, visualizaciones, una matriz de 21 variables y un perfil filtrado. El avance es sustantivo; aun así, subsisten decisiones de preparación que deben mejorarse.

3. Limpieza y preparación — 3,50/5,00

El estudiante parte de 2.535 registros y entrega una versión de 2.441 filas y 21 columnas. Corrige categorías, transforma TotalCharges a numérica, excluye Churn sin respuesta válida e informa cero duplicados y cero valores nulos en el resultado. Este paso supera la debilidad principal del trabajo anterior.

La observación técnica más importante es el orden de las operaciones: la instrucción data_clean = data_clean[data_clean['TotalCharges'] >= 0] elimina previamente todos los valores NaN de TotalCharges. En consecuencia, la imputación posterior con mediana no puede recuperar esos faltantes, aunque el texto dice que fueron imputados. Además, la salida informa 32 duplicados exactos eliminados en esa etapa, cifra que no debe confundirse con el diagnóstico de 35 duplicados del archivo original, porque ya se habían retirado otras filas. Para evaluar la pérdida total de 94 registros hace falta una tabla secuencial por motivo de exclusión.

Acción correctiva: cuantificar los registros descartados en cada paso, tratar los faltantes de TotalCharges antes de filtrar valores negativos y justificar cada eliminación. Debe distinguirse ausencia, valor imposible y valor extremo plausible.

4. Exploración general (EDA) — 4,75/5,00

El cuaderno presenta un diccionario y clasificación de las 21 variables con fuente consultada, reconocimiento de dimensiones y tipos, visualizaciones y matriz de decisiones con evidencia descriptiva y relacional. Se reconoce especialmente la amplitud y organización del EDA, así como la incorporación de mejoras respecto al taller anterior. Las inconsistencias puntuales de cifras y conclusiones se valoran de manera específica en los criterios de análisis univariado y bivariado, sin duplicar descuentos. Se mantiene la recomendación de precisar las justificaciones sobre la base finalmente depurada.

5. Análisis univariado — 3,75/5,00

Se presentan frecuencias y proporciones categóricas, distribución de Churn, histogramas, diagramas de caja e interpretación de describe() para tenure, MonthlyCharges y TotalCharges. El estudiante reconoce los cuartiles, la dispersión y la relación entre media y mediana.

No obstante, algunas cifras del Markdown no coinciden con la tabla calculada: en MonthlyCharges se afirma desviación estándar ≈32,8, mientras la salida muestra 25,39; en tenure se indica máximo 72, pero la salida es 71. También se informa desviación ≈15,8 para tenure cuando se obtuvo 15,26. Estas diferencias exigen revisar el texto tras ejecutar de nuevo el cuaderno.

6. Análisis bivariado — 4,00/5,00

Se comparan diez características categóricas con Churn mediante frecuencias, tasas por categoría y diferencias respecto de la tasa general de 39,74 %. También se

comparan las tres variables numéricas por grupo y se calcula una matriz de correlación. La evidencia y el uso de denominadores por categoría constituyen una fortaleza.

Debe cuidarse la interpretación. Por ejemplo, el texto afirma que quienes carecen de OnlineSecurity abandonan más; las tablas mostradas indican 41,36 % sin seguridad y 42,13 % con seguridad. Además, en la limpieza se usa capitalize(), por lo que DSL aparece como Dsl. Conviene cotejar cada conclusión con sus porcentajes y evitar atribuciones causales sobre el método de pago sin evidencia adicional.

7. Construcción y verificación del perfil — 4,50/5,00

El estudiante aplica correctamente un filtro conjunto: contrato mes a mes, internet de fibra óptica y pago mediante cheque electrónico. La salida del Colab permite verificar el tamaño, los abandonos y la tasa del segmento.

Indicador	Resultado del código	Texto del estudiante
Clientes del perfil	183	No consigna la cantidad
Clientes que abandonaron	127	No consigna la cantidad
Tasa de abandono del perfil	69,40 %	Indica que supera la tasa general, sin cifra precisa
Tasa general	39,74 %	Referencia general ≈40 %
Diferencia	29,66 puntos porcentuales	No cuantificada

El perfil está estadísticamente respaldado y su tasa supera la general en 29,66 puntos porcentuales. Para cerrar adecuadamente el entregable, la redacción final debe incorporar expresamente «183 clientes; 127 abandonos; 69,40 %», reconocer el tamaño relativamente pequeño del segmento y evitar afirmar que es el perfil de máxima tasa de toda la base sin comparar otras combinaciones.

8. Recomendaciones concretas

Primero, registrar en una tabla las filas eliminadas en cada etapa y revisar el tratamiento de TotalCharges. Segundo, actualizar describe() y las interpretaciones usando una única ejecución del notebook. Tercero, revisar las afirmaciones bivariadas contra las tasas obtenidas, en especial OnlineSecurity. Cuarto, reproducir en la conclusión del perfil las cantidades y porcentajes exactos del código.

9. Concepto final del docente

Miguel Alejandro Yela Vega evidencia una mejora importante frente a su primera entrega: pasó de identificar problemas sin resolverlos plenamente a construir una base depurada, analizar variables por separado, relacionarlas con el abandono y verificar un

segmento de clientes mediante un filtro conjunto. Su resultado de perfil —183 clientes, de los cuales 127 abandonaron (69,40 %)— muestra capacidad para convertir tablas en una conclusión útil para el negocio.

Para consolidar ese progreso debe trabajar la trazabilidad de la limpieza: no basta con informar una base sin nulos si algunas filas se perdieron antes de realizar la imputación anunciada. Asimismo, las cifras de las interpretaciones deben coincidir con las salidas y las asociaciones deben describirse sin atribuir causas no demostradas. La nota de 4,00/5,00 reconoce el avance y deja identificadas estas correcciones concretas.