Retroalimentación del grupo 1

Hotel Booking

Materia: Inteligencia de Negocios
Evaluación del Corte 2026-II
Docente: Julio Ricardo Martínez Montezuma
Integrantes: María José Barrios Ortega y Heitan Santiago Manquillo Tose

Caso de estudio y propósito de la revisión

Se analizan reservas de hoteles urbanos y de tipo resort. La pregunta es: ¿qué características individuales y combinadas se relacionan con la cancelación y cómo cambia la clasificación de una reserva al modificar el umbral de la regresión logística? La variable objetivo es cancelo: Y equivale a 1 y N a 0.

El grupo presenta una exploración amplia y construye correctamente el procedimiento central de regresión. El principal aspecto por mejorar es la correspondencia entre los cálculos y las explicaciones: algunas tasas, cantidades y perfiles escritos no coinciden con la data utilizada. Las observaciones siguientes muestran la evidencia y una forma de corregir cada punto.

Nota propuesta revisada: 3,6 sobre 5,0. Resultado ponderado: 3,55.

Rúbrica y valoración

Criterio	Peso	Nota 1 a 5	Aporte
Limpieza y diagnóstico	20 %	4,0	0,800
Exploración de los datos	15 %	3,5	0,525
Análisis univariado y bivariado y perfil	25 %	2,0	0,500
Regresión logística	25 %	4,5	1,125
Probabilidades y umbral	15 %	4,0	0,600
Total	100 %	3,55	3,55

Escala: 5 = completo y correctamente explicado; 4 = logrado con aspectos por ajustar; 3 = parcial; 2 = dificultades importantes; 1 = ausente o sin evidencia. Se admiten valores intermedios. La nota corresponde a la entrega revisada y queda a consideración del docente.

Se mantienen los términos del curso: univariado es una característica frente a la objetivo; bivariado es el cruce de dos características frente a la objetivo. La valoración se limita a lo enseñado: preparación, entrenamiento, probabilidades, clasificaciones, conteo de aciertos y comparación inicial de umbrales. No se exige matriz de confusión, medidas avanzadas, selección de umbral óptimo ni aciertos separados por clase.

Cómo comprobar las observaciones

Las referencias indican el título de la sección o el encabezado del bloque. Las tasas se calculan como reservas canceladas ÷ total de reservas del grupo × 100. Salvo indicación

distinta, las comprobaciones usan las 85.336 filas que quedan al aplicar la limpieza del grupo a datos.csv.

Se contrastaron el cuaderno Parcial2Corte_Barrios_Manquillo.ipynb y los resultados documentados de la Data 1 – Hotel Booking. La comprobación de cálculos seleccionados no equivale a reproducir íntegramente la sesión de Colab. Los valores comparativos respecto del archivo original se conservan como antecedentes de la revisión documentada.

No se descuenta por dudas sobre la carga inicial ni por eliminar filas idénticas en la tabla suministrada: la reducción de columnas de la data entregada puede producir coincidencias que no se observan en la original. La valoración de limpieza es 4,0; los demás criterios se valoran únicamente con evidencias comprobables y sin duplicar penalizaciones.

Limpieza y exploración

Limpieza y diagnóstico 4,0 sobre 5

Dónde revisar: «3. Calidad de datos», bloque «LIMPIEZA DE DATOS», y su interpretación. Reconocemos la identificación de ausentes, los reemplazos, el ajuste de tipos y la comprobación final de valores nulos. El aspecto por fortalecer es explicar los supuestos de esos reemplazos y cerrar la revisión de anomalías.

En la tabla entregada hay 4 vacíos en children. El grupo los reemplaza por 0, pero un vacío significa información no registrada y no confirma ausencia de niños. Pueden mantener ese reemplazo si lo justifican, por ejemplo verificando que 0 es el valor más frecuente. La media no es una solución automática: podría producir una cantidad fraccionaria de niños. El tamaño de la muestra no sustituye esta explicación.

En country, «Unknown» o «Desconocido» comunica adecuadamente que falta información. En agent y company, usar 0 requiere aclarar si representa “sin agencia o empresa” o “desconocido”; la ausencia del dato no demuestra por sí sola una reserva directa. Estas columnas no entran en los cuatro predictores del modelo presentado, de modo que sus reemplazos no modifican directamente sus probabilidades.

Evidencia pendiente de tratamiento: en la base posterior a su limpieza permanece 1 fila con adr negativo y 163 con adults + children + babies = 0. En «Análisis Bivariado Númerico», el filtro 0 < adr < 400 limita la gráfica, pero no cambia df. Revisen esos casos y expliquen si se conservan, corrigen o excluyen; no se exige eliminarlos automáticamente.

Filas idénticas y límites de la tabla suministrada

La base original tiene 32 columnas; la entregada, 27. La eliminación de filas idénticas retira 31.994 en la original y 34.054 en la entregada. Hay 2.060 registros adicionales que se distinguen en la original y dejaron de distinguirse al retirar columnas. Este efecto de la preparación del ejercicio no se atribuye a los estudiantes ni genera descuento.

Ejemplo verificable: los registros con índices 404 y 405 de la original coinciden en todas las columnas entregadas, pero booking_changes vale 0 y 1, respectivamente. Esa columna no estaba disponible para el grupo. Para documentar su decisión, basta reconocer esta limitación y mostrar el cambio de composición:

Base entregada	Reservas	Canceladas	Tasa
Antes de eliminar filas idénticas	119.390	44.224	37,04 %
Después de eliminarlas	85.336	23.594	27,65 %

Exploración de los datos 3,5 sobre 5

Reconocemos los resúmenes y las gráficas. Corrijan estas diferencias entre las salidas y la interpretación que las acompaña:

Dónde revisar	Texto del grupo	Salida comprobada
«ANÁLISIS DE CANCELACIONES GLOBALES»	37,04 %	27,65 % después de limpiar
«5. Variables Numericas» · mediana lead_time	45 días	48 días
«5. Variables Numericas» · mediana adr	92,50	99,00

Indiquen siempre si describen la base inicial o la depurada. El 37,04 % es válido para la inicial; el error es usarlo como explicación de una salida posterior a la limpieza. Como recomendación sin descuento, reinicien y ejecuten todo antes de entregar para guardar resultados de una misma secuencia.

Análisis univariado y bivariado y perfil

Valoración del criterio 2,0 sobre 5

Se reconocen los cálculos de tasas por característica frente a cancelo. La valoración responde a tres dificultades observables: interpretaciones que no coinciden con sus tablas, falta de un cruce calculado de dos características predictoras frente al objetivo y perfiles finales cuyas cantidades y tasas no corresponden a los filtros descritos. No se penaliza el nombre de las secciones.

Las tasas escritas no coinciden con las tablas

Dónde revisar: «11. Análisis Bivariado Categorico», bloque «PASO 6.2: ANÁLISIS BIVARIADO (CATEGÓRICAS VS CANCELO)», y la interpretación que sigue. Comprobación sobre la base depurada:

Categoría	Reservas	Canceladas	Tasa calculada	Texto
City Hotel	52.103	15.763	30,25 %	41,73 %
Groups	4.149	1.212	29,21 %	61,06 %
Online TA	51.210	18.058	35,26 %	36,72 %

Por ejemplo, 1.212 ÷ 4.149 × 100 = 29,21 %. Online TA supera a Groups en la tabla depurada; por eso no pueden justificar el perfil de Groups con 61,06 %. Actualicen la interpretación desde la tabla que realmente utilizaron. Esta diferencia afecta la selección del perfil, aunque corregir el texto por sí solo no cambia el modelo.

Falta demostrar el cruce de dos características

El bloque anterior calcula hotel, market_segment, deposit_type y customer_type por separado frente a cancelo. Esto acredita el univariado acordado en clase. Para el bivariado, presenten una tabla que combine dos características y muestre total de

reservas, canceladas y tasa por combinación. Enumerar atributos en la conclusión no sustituye ese cálculo.

Los perfiles finales no reproducen sus cifras

Dónde revisar: «15. Interpretación y Evidencia Empírica de Perfiles al Momento de la Reserva». Se comprobaron las condiciones descritas en el texto:

Perfil A: hotel = City Hotel; market_segment = Online TA; deposit_type = Non Refund o No Deposit; customer_type = Transient. Perfil B: hotel = Resort Hotel; market_segment = Direct o Corporate; deposit_type = No Deposit; customer_type = Contract o Transient-Party.

Perfil	Entrega reservas y tasa	Verificación reservas	Canceladas	Tasa verificada
A	29.845 · 61,20 %	31.785	11.972	37,67 %
B	14.210 · 13,84 %	831	88	10,59 %

Las tasas verificadas son 11.972 ÷ 31.785 y 88 ÷ 831, multiplicadas por 100. Tampoco se reproducen en la base inicial: los mismos filtros dan 35.092 reservas y 39,33 % para A, y 1.220 y 14,75 % para B. Además, la tabla resumen omite No Deposit en A y cambia Transient-Party por Group en B.

Para mejorar, definan un único filtro por perfil y muestren su cálculo. Pueden usar una o dos características, como se trabajó en clase. Comparen su tasa con la tasa global de la misma base. Eviten afirmar que “garantiza la ocupación”: el porcentaje de reservas no canceladas no mide la ocupación hotelera y una asociación no demuestra una causa.

Regresión logística y umbrales

Regresión logística 4,5 sobre 5

En «SEPARACIÓN Y VALIDACIÓN METODOLÓGICA» seleccionan hotel, market_segment, deposit_type y customer_type y convierten cancelo en 0/1. En «CONSTRUCCIÓN DEL PIPELINE» (nombre del bloque del Colab; flujo de trabajo [Pipeline] en la explicación) y «PASO AJUSTE (ENTRENAMIENTO) DEL MODELO», la codificación y la regresión se ajustan con entrenamiento. El procedimiento central es correcto; las comprobaciones documentadas respaldan los conteos de predicción y aciertos. La selección de las cuatro variables es una decisión de modelado; el análisis de perfiles previo no demuestra por sí solo que sean las óptimas.

Corrección verificable en «DIVISIÓN ESTRATIFICADA (80% / 20%)» y la interpretación del entrenamiento:

Conjunto	Texto del grupo	Salida y comprobación
Entrenamiento	68.269	68.268
Prueba	17.067	17.068

Actualicen las cantidades del texto. La diferencia es de una fila y no invalida el reparto realizado. En «PASO MUESTRA DE PREDICCIONES Y PROBABILIDADES», las diez reservas mostradas tienen probabilidades entre 0,0451 y 0,3728 y todas dan clase 0. La explicación añade casos de 0,68 y 0,85 que no aparecen en esa muestra: identifíquenlos como hipotéticos o sustitúyanlos por casos realmente mostrados.

Probabilidades y umbral 4,0 sobre 5

Dónde revisar: «PASO COMPARACIÓN DE UMBRALES (50%, 65% Y 80%)», «PASO CONTEO DE ACIERTOS Y ERRORES EN PRUEBA» y sus interpretaciones. Los conteos del código son correctos. Esta comparación muestra el resultado comprobado sobre las 17.068 reservas de prueba:

Umbral	Predice 1	Predice 0	Aciertos	Porcentaje de acierto
0,50	190	16.878	12.519	73,3478 %
0,65	189	16.879	12.518	73,3419 %
0,80	189	16.879	12.518	73,3419 %

En «Interpretación y Análisis del Cuadro de Aciertos y Errores en Prueba» se escribe un rango de 72,8 %–73,0 %. La tabla arroja aproximadamente 73,35 %: con umbral 0,50, 12.519 ÷ 17.068 × 100 = 73,35 %. Corrijan el rango. Entre 0,50, 0,65 y 0,80, el primero obtuvo un acierto más; no puede afirmarse que sea el mejor umbral entre todos los posibles.

La comparación permite formular una conclusión concreta: al subir el umbral de 0,50 a 0,65, una reserva pasa de clase 1 a clase 0 y los aciertos disminuyen de 12.519 a 12.518; al subir a 0,80, no hay cambios adicionales. Se observa una tendencia en los valores estudiados, no una regla general. Como hipótesis para la siguiente lección podría investigarse qué ocurre por debajo de 0,50; eso no garantiza un aumento de aciertos. El umbral cambia la clase asignada, no la probabilidad estimada.

La explicación debe distinguir predicciones de clase 1, cantidad de aciertos y porcentaje de aciertos. Eviten atribuir a los conteos cambios específicos en tipos de error sin haberlos comprobado. No se exige matriz de confusión ni indicadores no enseñados.

Como contexto interpretativo, el 72,35 % del conjunto de prueba pertenece a la clase 0; el modelo alcanza 73,35 % de aciertos generales con umbral 0,50. El 1,1 % predicho como clase 1 señala la proporción clasificada como cancelación, no su porcentaje de aciertos. Tampoco puede deducirse de la exactitud general cuántos aciertos corresponden a cada clase.

Prioridad de mejora

Conserven el procedimiento de regresión logística, que está correctamente implementado. Primero actualicen los textos con las salidas verdaderas; luego reconstruyan el cruce de dos características y verifiquen las cantidades y tasas de los perfiles. Finalmente, cierren la comparación de umbrales indicando qué cambió, qué no cambió y qué hipótesis merece estudiarse a continuación. Corregir el texto no modifica por sí mismo las probabilidades del modelo.

Conclusión de la evaluación

La nota propuesta es 3,6 sobre 5,0, a partir del resultado ponderado 3,55. El grupo reconoce el caso de cancelación de reservas y aplica correctamente el procedimiento central de regresión logística. La principal dificultad consiste en conectar los cálculos de exploración con un perfil verificable y una conclusión coherente con la evidencia. La calificación no depende de alcanzar determinado porcentaje de aciertos ni de contenidos todavía no enseñados.

Criterio evaluado	Nota	Aprendizaje por reforzar
Limpieza y diagnóstico	4,0	Justificar los reemplazos de datos ausentes y documentar el tratamiento de anomalías.
Exploración de los datos	3,5	Interpretar las cifras de la tabla utilizada y distinguir la base inicial de la depurada.
Análisis univariado y bivariado y perfil	2,0	Cruzar dos características con la objetivo y respaldar el perfil con cantidades y tasas comprobables.
Regresión logística	4,5	Mantener la implementación correcta y ajustar la explicación a las salidas que realmente se muestran.
Probabilidades y umbral	4,0	Distinguir el cambio de clase asignada del cambio en el porcentaje de aciertos.

Por qué se obtiene esta nota

La mayor dificultad está en el análisis y el perfil, criterio que pesa el 25 %. Se reconocen las tasas individuales, pero algunas interpretaciones usan cifras distintas, falta demostrar el cruce de dos características y los perfiles no coinciden con sus filtros. Esto limita la respuesta al caso de estudio.

La regresión es la parte mejor lograda: separan entrenamiento y prueba, codifican las categorías y calculan probabilidades correctamente. No se descuenta por la duda sobre la carga inicial ni por eliminar filas idénticas de la tabla suministrada.

Qué deben poder explicar después de corregir

Elijan un perfil y expliquen sus condiciones, cuántas reservas lo cumplen, cuántas cancelaron y cómo calcularon la tasa. Compárenla con la tasa general de la misma base y redacten una conclusión sustentada en esas cifras.

En el umbral, expliquen que pasar de 0,50 a 0,65 mueve una reserva de 1 a 0 y reduce los aciertos en uno; pasar a 0,80 no produce cambios adicionales. Esa observación permite plantear una hipótesis sobre otros valores para una clase posterior, pero no demostrar que un umbral menor sea necesariamente mejor.

Aprendizaje prioritario para reforzar en clase

Interpretación de tasas y construcción de perfiles mediante dos características y la objetivo. La entrega evidencia dificultades para conectar cálculos y conclusiones, pero no demuestra que no comprendieran la pregunta. Una explicación oral del perfil permitirá distinguir una dificultad conceptual de un texto desactualizado.