Retroalimentación del grupo 4
Kickstarter – Data 4

Asignatura: Inteligencia de Negocios | Evaluación del II Corte 2026-II

Docente: Julio Ricardo Martínez Montezuma

Integrantes: Anny Daiana Trujillo Ortega y Carlos Eduardo Valencia Núñez.

Caso de estudio y propósito de la revisión

Pregunta: Al comenzar una campaña de financiación colectiva, ¿qué probabilidad tiene de finalizar con éxito? La variable objetivo exito identifica Y = éxito (1) y N = fracaso (0). Se revisó el cuaderno «parcial_de_trujillo_and_valencia (2).ipynb» y se contrastaron hechos seleccionados con la base Kickstarter suministrada (331.675 proyectos).

Resultado propuesto: 4,00/5,00. El trabajo sí desarrolla los cruces de dos características y construye dos perfiles cuantificados, a diferencia de otros grupos. La principal observación se refiere a comparar metas monetarias expresadas en distintas monedas como si todas fueran dólares; ese supuesto afecta la interpretación y también alimenta el modelo.

Rúbrica y valoración

Criterio	Peso	Nota / 5,00	Aporte
Limpieza y diagnóstico	20 %	4,00	0,800
Exploración de datos	15 %	4,00	0,600
Análisis univariado, bivariado y perfil	25 %	3,50	0,875
Regresión logística	25 %	4,50	1,125
Probabilidades y umbral	15 %	4,00	0,600
TOTAL	100 %	—	4,000

Escala: 5,00 = completo y correctamente explicado; 4,00 = logrado con ajustes; 3,00 = parcial; 2,00 = dificultades importantes; 1,00 = ausencia de evidencia. Se valoran solamente los contenidos trabajados en clase. No se exigen matrices de confusión ni indicadores avanzados. La nota corresponde a una propuesta docente sustentada en el cuaderno y comprobaciones selectivas.

Comprobación de las observaciones

Las referencias se hacen por encabezado o bloque del Colab, no por números de celdas. Los resultados guardados en el cuaderno se distinguen de las verificaciones directas sobre el CSV; no se afirma haber reproducido íntegramente la sesión de Google Colab.

Limpieza y diagnóstico — 4,00/5,00

Dónde revisar: «2. Carga, reconocimiento y limpieza», «PROCESO DE LIMPIEZA Y TRANSFORMACIÓN» y «Reporte de Decisiones de Limpieza». Aciertos: identifican 0 filas idénticas y 0 ID repetidos; localizan 3 ausencias en name, normalizan textos, convierten fechas, calculan duración y transforman Y/N a 1/0. En la base entregada se confirman 210 valores anómalos N,0" en country, tal como reportan.

Dificultad verificable: el código aplica astype(str) a todas las columnas de texto ANTES de ejecutar fillna en name. Esto transforma un valor ausente en la cadena literal «nan»; por tanto, fillna("Unknown") no corrige esas tres ausencias como afirma el informe. Que después aparezcan 0 nulos en isnull() no prueba que hayan desaparecido las ausencias disfrazadas. Deben preservar los nulos durante la normalización o corregir explícitamente esa cadena y volver a comprobar. Ajuste de valoración docente: el criterio se sitúa en 4,00/5,00 porque el diagnóstico y la preparación están sustancialmente logrados; el error puntual en name permanece señalado para corrección, sin ignorarlo ni descontarlo de nuevo en otro criterio.

También deberían revisar explícitamente si las duraciones y metas son plausibles y documentar los criterios antes de adoptar rangos. No se exige borrar extremos automáticamente.

Exploración de datos — 4,00/5,00

Dónde revisar: «3. EXPLORACIÓN DE VARIABLES CATEGÓRICAS» y «4. EXPLORACIÓN DE VARIABLES NUMÉRICAS». El grupo presenta frecuencias de categorías, monedas y países, distribución Y/N, estadísticos de goal y duration_days e histogramas, y justifica por qué no emplea identificadores o información posterior al lanzamiento. La base contiene 197.719 fracasos (59,61 %) y 133.956 éxitos (40,39 %).

La limitación central es el significado económico de goal: el CSV contiene metas expresadas en la moneda especificada en currency, no valores previamente convertidos a USD. Por ejemplo, los valores habituales de JPY y USD no son directamente comparables. Las etiquetas «<1k USD» o «>20k USD» de la exploración numérica no describen correctamente todas las filas. Debe corregirse el lenguaje y preferiblemente convertir a una moneda común antes de comparar montos.

Análisis univariado, bivariado y perfil — 3,50/5,00

Dónde revisar: «5. ANÁLISIS UNIVARIADO», «6. Análisis Bivariado, Perfiles y Cierre ML» y «CUANTIFICACIÓN Y EVIDENCIA EMPÍRICA DE PERFILES». Reconocimiento importante: sí calculan tasas por característica y sí realizan dos cruces que cumplen la convención de clase: main_category × grupos_goal, y grupos_duracion × grupos_goal, frente a exito_bin. Es incorrecto afirmar que falta el bivariado.

También formulan y cuantifican perfiles concretos: perfil de Theater/Dance/Music, meta <1k en moneda original y duración ≤35 días: n = 5.966 y éxito observado = 64,35 %; perfil Technology/Food, meta ≥20k en moneda original y duración >35 días: n = 7.272 y éxito observado = 17,19 %. Los comparan con 40,39 % global. Esta evidencia cumple la finalidad de conectar cruces con perfiles.

El descuento se fundamenta en que la interpretación convierte metas nominales de distintas monedas en dólares uniformes. Por ello, las tasas pueden describir grupos generados por los filtros, pero no respaldan las afirmaciones «menos de 1.000 USD» o «más de 20.000 USD» para toda la base. Las explicaciones sobre fidelización, urgencia o motivos del éxito son hipótesis, no causas comprobadas por el análisis. Deben indicar además número de éxitos por perfil, junto al denominador y la tasa.

Regresión logística — 4,50/5,00

Dónde revisar: «7. PREPARACION DE LOS DATOS PARA EL ENTRENAMIENTO DEL MODELO», «ENTRENAR LA REGRESIÓN LOGÍSTICA» y «PREDECIR Y APLICAR UMBRALES». Seleccionan cinco características iniciales, separan 265.340 registros (80 %) para entrenamiento y 66.335 (20 %) para prueba con estratificación, codifican categorías y entrenan el modelo mediante un flujo de trabajo (Pipeline). La implementación de X/y, codificación y entrenamiento es coherente con el alcance enseñado.

La salvedad no es un fallo del algoritmo: grupos_goal proviene de cantidades no homologadas entre monedas, lo que limita el significado de sus predictores y algunas interpretaciones comerciales. En el código es correcto conservar Pipeline como nombre de la clase de Python, pero en el texto académico utilizaremos «flujo de trabajo (Pipeline)».

Probabilidades y umbral — 4,00/5,00

Dónde revisar: «5.3. Cambiar el umbral», «5.4. Contar aciertos y errores» y «8. Conclusiones Generales». Calculan predict_proba, muestran ejemplos, prueban los umbrales 0,50, 0,65 y 0,80, e identifican correctamente que elevar el umbral reduce las predicciones de éxito sin modificar las probabilidades estimadas.

Umbral	Predice éxito (1)	Aciertos	Errores	Aciertos (%)
0,50	18.411	42.953	23.382	64,75 %
0,65	3.775	40.839	25.496	61,56 %
0,80	109	39.605	26.730	59,70 %

Interpretación sustentada: de los tres umbrales examinados, 0,50 obtuvo más aciertos, y se podría formular la hipótesis de explorar valores inferiores en una lección posterior. Debe retirarse la afirmación de que 0,50 es el «umbral óptimo» o que ofrece el «equilibrio idóneo»: no se probaron todos los umbrales ni se evaluó aquí una decisión de negocio con costos conocidos. También debe evitarse equiparar una probabilidad estimada del 86,38 % para un caso hipotético con una «fórmula de mayor certeza» de éxito real.

Conclusión de la evaluación

Nota propuesta: 4,00/5,00. El Grupo 4 realiza un trabajo completo y ordenado de exploración, sí presenta los dos cruces de características enseñados y documenta dos perfiles con tamaños y tasas concretas. Entrena correctamente la regresión logística y muestra cómo las clasificaciones y los aciertos cambian según el umbral.

La prioridad de corrección es conceptual y transversal: goal está en monedas diferentes y sus rangos fueron rotulados e interpretados como si fueran dólares. También deben corregir el tratamiento de ausencias disfrazadas y distinguir asociaciones observadas de explicaciones causales. Estos ajustes mejoran la interpretación sin desconocer lo que sí hicieron correctamente.

Aprendizaje prioritario para reforzar en clase: significado y comparabilidad de las variables antes de construir perfiles y predictores. Para el análisis del umbral basta, en este corte, con comparar los aciertos observados y formular una hipótesis razonada; no se exigirá encontrar un umbral definitivo ni calcular indicadores todavía no enseñados.