Retroalimentación del grupo 5
Titanic – Data 5

Materia: Inteligencia de Negocios | Evaluación II Corte 2026-II

Docente: Julio Ricardo Martínez Montezuma

Integrante identificado en el Colab: Santiago Rosada Otero

Archivo revisado: Titanic_Regresion_Logistica_Caso05.ipynb | Base: datos.csv

Caso de estudio y propósito

Pregunta de negocio: ¿cómo se relacionan las características de los pasajeros con su probabilidad de supervivencia? La variable objetivo es sobrevivio: Y = sobrevivió (1) y N = no sobrevivió (0). La base contiene 1.309 pasajeros y 12 columnas. El trabajo incluye 83 celdas y salidas de ejecución guardadas.

Rúbrica y valoración

Criterio	Peso	Nota / 5,00	Aporte
Limpieza y diagnóstico	20 %	4,50	0,900
Exploración de datos	15 %	4,50	0,675
Análisis univariado, bivariado y perfil	25 %	3,50	0,875
Regresión logística	25 %	4,50	1,125
Probabilidades y umbral	15 %	4,75	0,713
TOTAL	**100 %**		**4,29**

Nota final propuesta: 4,29 / 5,00. Se reconoce especialmente el rigor del diagnóstico, los cruces de características y la explicación de los umbrales. La principal oportunidad de mejora es cerrar el análisis con un perfil histórico respaldado por cantidad de pasajeros, número de sobrevivientes y tasa correspondiente.

Método de comprobación

Se revisaron las 83 celdas, el código y sus salidas guardadas. Las cifras citadas provienen del cuaderno; no se ejecutó nuevamente el modelo para generar métricas distintas. La valoración se limita a los contenidos enseñados: calidad de datos, exploración, análisis de una y dos características, perfil, separación entrenamiento/prueba, regresión logística y conteo de aciertos con distintos umbrales.

1. Limpieza y diagnóstico – 4,50 / 5,00

Dónde revisar: secciones 3 a 5. Se identifican ausencias en cabin (1.014; 77,46 %), home.dest (564; 43,09 %), age (263; 20,09 %), embarked (2) y fare (1). Se verifican duplicados exactos (0) y nombres repetidos, sin eliminar pasajeros distintos por compartir nombre. También se revisan categorías válidas y rangos numéricos.

El estudiante fundamenta la mediana para fare (asimetría 4,37), la media para age (asimetría 0,41), la moda para embarked y la transformación de cabin en el indicador cabina_conocida. Excluye home.dest, ticket y el nombre original para el modelado, y deriva titulo del nombre. La matriz de decisiones hace explícito qué conserva y por qué.

Por mejorar: age, fare y embarked se imputan antes de separar entrenamiento y prueba; es preferible calcular las estadísticas de imputación exclusivamente con entrenamiento y aplicarlas luego a prueba. La asociación entre cabina registrada y clase está respaldada; su explicación histórica sobre prácticas de registro debe mantenerse como hipótesis, no como hecho comprobado.

2. Exploración de datos – 4,50 / 5,00

Dónde revisar: secciones 3, 6 y salidas gráficas. La distribución de la respuesta está correctamente documentada: 809 pasajeros no sobrevivieron (61,8 %) y 500 sobrevivieron (38,2 %). Se interpretan describe(), diagramas de caja, tarifas, edad, clases, sexo, puertos de embarque, títulos y disponibilidad de cabina.

Los gráficos son pertinentes y la interpretación suele distinguir relaciones observadas de explicaciones plausibles. Se advierte, por ejemplo, que la diferencia según puerto podría estar vinculada con la clase del pasajero. Como mejora, conviene no convertir asociaciones en afirmaciones causales sobre decisiones de evacuación; el conjunto de datos por sí solo no prueba dichos mecanismos.

3. Análisis univariado, bivariado y perfil – 3,50 / 5,00

Dónde revisar: secciones 6 y 7. De acuerdo con la convención del curso, el univariado compara una característica predictora con la respuesta. El estudiante presenta tasas verificables: mujeres 72,75 % frente a hombres 19,10 %; primera clase 61,92 %, segunda 42,96 % y tercera 25,53 %. También analiza puerto, título, cabina conocida y grupos de edad.

A diferencia de grupos que solo realizan análisis individuales, este trabajo sí cruza dos atributos simultáneamente con la supervivencia: pclass + sex y grupo_edad + sex. Interpreta, por ejemplo, la supervivencia de mujeres por clase (96,5 % en primera, 88,7 % en segunda y 49,1 % en tercera). Este cumplimiento del componente bivariado debe reconocerse de manera explícita.

La limitación está en el cierre del perfil: no se formula un grupo seleccionado con su condición doble claramente definida y, en una tabla verificable, el total de pasajeros que cumplen esa condición, cuántos sobrevivieron y qué porcentaje representa. Las tasas narradas son útiles, pero sin los conteos no permiten comprobar de forma completa el perfil exigido. Se recomienda concluir con una tabla de perfil histórico y comparar su tasa con el 38,2 % general.

4. Regresión logística – 4,50 / 5,00

Dónde revisar: secciones 8 a 11. Se seleccionan nueve características, se prepara X e y con la respuesta Y/N convertida a 1/0 y se realiza la división estratificada de 80 % entrenamiento (1.047 pasajeros) y 20 % prueba (262). Las variables categóricas se codifican mediante One-Hot Encoding y el modelo se ajusta con LogisticRegression, dentro de un flujo de trabajo (Pipeline) de preparación y aprendizaje.

Las salidas muestran que el entrenamiento finaliza y que el modelo reconoce las clases [0, 1]. Es pertinente excluir identificadores originales y justificar cada predictor. La reserva metodológica principal es la imputación previa a la partición: aun cuando en este tamaño de base la diferencia pudiera ser pequeña, los parámetros de limpieza no deberían aprenderse de las filas de prueba.

5. Probabilidades y umbral – 4,75 / 5,00

Dónde revisar: secciones 12 a 14. Se obtiene predict_proba para los 262 registros de prueba y se aplican los umbrales 0,50, 0,65 y 0,80, dejando constantes las probabilidades estimadas. Se muestra un registro de prueba y un caso nuevo construido manualmente. Las salidas permiten comprobar la siguiente comparación:

Umbral	Predichos como 1	Aciertos / 262	% aciertos
0,50	93	219	83,59 %
0,65	71	217	82,82 %
0,80	**44**	**200**	**76,34 %**

El análisis identifica correctamente que subir el umbral reduce los casos clasificados como sobrevivientes (93 → 71 → 44) y que, en esta prueba, disminuye el porcentaje global de aciertos. Interpreta el cambio sin afirmar que 80 % sea un umbral mejor. Aunque agrega conteos de tipos de error, estos no constituyen exigencia de esta evaluación ni generan puntos extra automáticos. Una mejora menor sería explicar siempre los aciertos simples antes de extenderse a terminología más avanzada.

Conclusión pedagógica y recomendaciones

El trabajo evidencia dominio de la lógica central de la regresión logística: preparar datos, estudiar relaciones, separar conjuntos, entrenar y convertir probabilidades en

decisiones bajo distintos umbrales. También evidencia un análisis bivariado real, que es un avance significativo respecto de entregas donde solo se comparó una característica por vez.

Para completar el objetivo del taller, se recomienda: (1) construir una tabla final de perfil con dos condiciones predictoras, número total de casos, número de sobrevivientes y tasa; (2) calcular las imputaciones después de dividir los datos, utilizando únicamente el conjunto de entrenamiento; y (3) mantener separadas las observaciones estadísticas y sus posibles causas históricas. La valoración propuesta es 4,29 / 5,00, de acuerdo con los cinco criterios y sus ponderaciones.