Retroalimentación del grupo 6

Hotel Booking

Materia: Inteligencia de Negocios
Evaluación del II Corte 2026-II
Docente: Julio Ricardo Martínez Montezuma
Integrantes: Diego Alejandro Chicangana Campo y Kevin Andrés Pira Sánchez

Caso de estudio y propósito de la revisión

La base registra reservas hoteleras. Se evalúa qué características de una reserva se relacionan con su cancelación y cómo cambia la clasificación al modificar el umbral de una regresión logística. La variable objetivo «cancelo» contiene Y (cancelación, 1) y N (no cancelación, 0).

Nota propuesta: 3,5 sobre 5,0 (ponderado exacto: 3,475). Se reconoce una implementación adecuada de regresión logística y una comparación explícita de umbrales. Las principales mejoras pendientes son construir un cruce de dos características con la variable objetivo, sustentar un perfil y confrontar interpretaciones con las salidas.

Rúbrica y valoración

Criterio	Peso	Nota 1 a 5	Aporte
Limpieza y diagnóstico	20 %	4,0	0,800
Exploración de datos	15 %	3,5	0,525
Análisis univariado, bivariado y perfil	25 %	2,0	0,500
Regresión logística	25 %	4,5	1,125
Probabilidades y umbral	15 %	3,5	0,525
TOTAL	100 %		3,475

Escala compartida: 5 = completo y bien explicado; 4 = logrado con aspectos por ajustar; 3 = parcial; 2 = dificultades importantes; 1 = ausente o sin evidencia. Se admiten valores intermedios. La nota queda a consideración del docente.

Alcance de la comprobación

Se contrastaron el cuaderno «PARCIAL_PARA_INTELIGENCIA_DE_NEGOCIOS (1).ipynb», sus salidas guardadas y el archivo «datos.csv» entregado (119.390 filas y 27 columnas). La revisión no equivale a ejecutar nuevamente toda la sesión de Colab. Se usa la denominación acordada en clase: univariado = una característica frente al objetivo; bivariado = dos características combinadas frente al objetivo. No se exige matriz de confusión ni métricas ajenas al alcance del curso.

Limpieza y diagnóstico — 4,0/5,0

Dónde revisar: «Análisis de los hallazgos y decisiones de limpieza», bloque que transforma «cancelo» y realiza imputaciones, y comprobación posterior de nulos. El grupo identifica las ausencias (children: 4; country: 488; agent: 16.340; company: 112.593), transforma Y/N a 1/0 y comprueba que no quedan nulos.

Por mejorar: reemplazar children faltante por 0 no demuestra que la reserva no incluya niños; debe justificarse con el contexto o distribución. Tampoco puede concluirse, únicamente por el nulo, que agent/company signifiquen reserva directa; «no aplica» es una decisión de codificación que necesita explicitar el supuesto. Es positivo excluir estos dos identificadores del modelo.

En el CSV compartido hay 1 registro con adr negativo y 180 registros donde adults + children + babies = 0 (contando nulos de children como 0 para la comprobación). Deben revisar y documentar si conservar, corregir o excluir esos casos. No se exige borrarlos automáticamente.

Exploración de datos — 3,5/5,0

Dónde revisar: «2. Exploración de Datos», tasas de deposit_type, gráfico de depósitos, correlaciones y boxplot de lead_time. La base respalda las tasas mostradas: Non Refund = 99,36 %; No Deposit = 28,38 %; Refundable = 22,22 %. Se valora el uso de tablas, agrupaciones y visualizaciones.

La explicación del gráfico de depósitos plantea la posibilidad de que «Non Refund» cancele menos, pero la tabla calculada muestra lo contrario. Debe redactarse una conclusión con los porcentajes obtenidos, en lugar de dejar hipótesis alternativas sin resolver. Sobre lead_time, la correlación aproximada de 0,293 señala asociación positiva; no demuestra por sí sola un aumento «drástico» de la probabilidad ni una causa. Eviten expresiones como «hemos comprobado» cuando solo se observó asociación.

Análisis univariado, bivariado y perfil — 2,0/5,0

Dónde revisar: tasas por deposit_type y market_segment, correlación y gráfico de lead_time, y la conclusión del EDA. Se reconoce el análisis de características individuales frente a «cancelo» (univariado según la convención del curso).

No se identifica una tabla calculada que cruce simultáneamente dos características predictoras, por ejemplo hotel + deposit_type, frente a «cancelo» y presente reservas totales, reservas canceladas y tasa por combinación. Tampoco se construye un perfil final reproducible a partir de un filtro definido y de cantidades verificables. Nombrar varias características o mostrar gráficas separadas no reemplaza este ejercicio.

Para corregir: definan una combinación concreta; documenten el filtro; cuenten reservas y canceladas; calculen tasa = canceladas / reservas × 100; compárenla con la tasa general

de 37,04 % de esta base sin eliminación de filas. El perfil debe concluir únicamente lo respaldado por esas cifras, sin afirmar causalidad.

Regresión logística — 4,5/5,0

Dónde revisar: «3. Preparación de Datos y Regresión Logística» y «Entrenamiento del Modelo (Pipeline)». Se observa una división 80/20 (95.512 registros de entrenamiento y 23.878 de prueba), identificación automática de 9 variables categóricas y 15 numéricas, y un Pipeline con StandardScaler, OneHotEncoder y LogisticRegression. Las transformaciones quedan integradas en el ajuste de entrenamiento. La salida guardada registra entrenamiento exitoso.

Por fortalecer: justificar por qué todas las variables restantes son adecuadas para pronosticar en el momento de la reserva. También conviene explicar que la división usada no está estratificada (no contiene stratify=y); no es un error automático, pero la conservación de proporciones merece comprobarse. La salida guardada acredita ejecución, no una validación exhaustiva del modelo.

Probabilidades y umbral — 3,5/5,0

Dónde revisar: «4. Evaluación de Umbrales Probabilísticos» y «5. Conclusión de Negocio y Análisis del Desplazamiento». El grupo usa correctamente predict_proba para la clase 1 y compara 0,50, 0,65 y 0,80. Los conteos guardados son:

Umbral	Predice cancelación (1)	Predice no cancelación (0)
0,50	7.106	16.772
0,65	5.261	18.617
0,80	3.933	19.945

Está bien interpretado que subir el umbral reduce las predicciones de cancelación: entre 0,50 y 0,80 pasan 3.173 reservas de clase 1 a clase 0. Sin embargo, el cuaderno no resume en texto cuántos aciertos produce cada umbral; los conteos de clases predichas no son un conteo de aciertos. Para cumplir el alcance de la guía, presenten aciertos y errores obtenidos al comparar cada predicción con el valor real, sin necesidad de matriz de confusión.

La conclusión sobre más falsos negativos al aumentar el umbral resulta plausible con este mecanismo, pero debe vincularse con datos calculados si se afirma que efectivamente aumentaron. Tampoco un umbral de 0,80 hace la evidencia «innegable»: sigue siendo una probabilidad estimada. La recomendación de negocio requiere justificar qué errores interesan y limitar la afirmación a los resultados comprobados.

Conclusión de la evaluación

Calificación propuesta: 3,5/5,0. El equipo demuestra manejo del procedimiento de preparación y entrenamiento y comprende la dirección en la que cambian las clases al aumentar el umbral. Pierde principalmente puntos en el criterio de análisis univariado,

bivariado y perfil (25 %), porque no presenta el cruce de dos características ni un perfil sustentado con cantidades y tasas.

Criterio	Nota	Aprendizaje prioritario
Limpieza y diagnóstico	4,0	Justificar imputaciones y revisar anomalías.
Exploración	3,5	Hacer concordar conclusiones y tasas calculadas.
Univariado, bivariado y perfil	2,0	Cruzar dos atributos y documentar el perfil.
Regresión logística	4,5	Justificar predictores y comprobar la partición.
Probabilidades y umbral	3,5	Distinguir asignaciones de clase y aciertos.

Qué deben poder explicar después de corregir: ¿cuántas reservas cumplen el perfil propuesto?, ¿cuántas cancelan?, ¿cuál es su tasa y en qué difiere del 37,04 % general? Además, ¿cuántos aciertos se obtienen con 0,50, 0,65 y 0,80?

Aprendizaje prioritario para reforzar en clase: pasar de tasas individuales a cruces de dos características y perfiles verificables; distinguir la probabilidad, la clase predicha y la exactitud observada. Este patrón coincide con la dificultad detectada en el Grupo 1, aunque su manifestación es distinta: allí se presentaron perfiles con cifras inconsistentes y aquí falta construir el perfil requerido.