Retroalimentación del grupo 7

Citas Médicas (Brasil)

Materia: Inteligencia de Negocios
Evaluación del II Corte 2026-II
Docente: Julio Ricardo Martínez Montezuma
Integrantes: Julián Alberto Liz Valencia y Juan Manuel Manzano Truque

Caso de estudio y propósito de la revisión

Pregunta: ¿qué citas médicas tienen mayor probabilidad de inasistencia? La variable objetivo es no_asistio: Y → 1 (no asistió) y N → 0 (asistió). El propósito es pasar del diagnóstico, exploración y análisis de características a un perfil de riesgo y después a un modelo inicial de regresión logística.

El grupo destaca por su diagnóstico de extremos, preparación del tiempo de espera y división de entrenamiento y prueba por pacientes. Debe fortalecer el cruce simultáneo de dos características y la construcción de un perfil sustentado. Nota propuesta: 3,6 / 5,0; suma ponderada: 3,575.

Rúbrica y valoración

Criterio	Peso	Nota 1 a 5	Aporte
Limpieza y diagnóstico	20 %	4,5	0,900
Exploración de los datos	15 %	3,5	0,525
Análisis univariado, bivariado y perfil	25 %	2,0	0,500
Regresión logística	25 %	4,5	1,125
Probabilidades y umbral	15 %	3,5	0,525
TOTAL	100 %	3,575	3,575

Escala: 5 = completo y correctamente explicado; 4 = logrado con aspectos por ajustar; 3 = parcial; 2 = dificultades importantes; 1 = ausente o sin evidencia. Se admiten valores intermedios. La nota queda a consideración del docente.

Cómo comprobar las observaciones

Se contrastaron «TallerFinal.ipynb», sus resultados guardados y el archivo datos.csv correspondiente a Citas Médicas. Las referencias señalan encabezados de secciones y bloques; no se exige matriz de confusión ni indicadores posteriores a lo enseñado. Se distinguen los cálculos del grupo de las verificaciones complementarias utilizadas en esta revisión. No se afirma que se haya reproducido integralmente el entorno original de Google Colab.

Limpieza y exploración

Limpieza y diagnóstico 4,5 sobre 5

Dónde revisar: «Revisión de duplicados y nulos», «Análisis Estadístico de Extremos» y «Acción de Limpieza». Se comprueban 110.527 registros y 14 columnas, ausencia de nulos y duplicados exactos; se transforma Y/N a 1/0, se normalizan fechas y se calcula WaitDays. Se retiran una edad negativa y cinco esperas negativas; quedan 110.521 filas. Después se documentan percentiles y se excluyen cinco edades superiores a 110 años: base final de 110.516 filas.

Fortaleza: a diferencia de una eliminación automática, el grupo explica los extremos y presenta percentiles. Ajuste: afirmar que edades > 110 son necesariamente errores de digitación o registros de prueba excede la evidencia; conviene hablar de registros improbables que requieren verificación, y justificar la exclusión como decisión didáctica. Además, describir Handcap según su codificación 0–4 antes de asumir que es binaria. No se descuenta por decidir conservar o retirar un extremo si la decisión está motivada.

Exploración de los datos 3,5 sobre 5

Dónde revisar: «Analisis Univariado y Bivariado», histogramas «Edad» y «Días de Espera». Presentan distribución de la variable objetivo, gráficos de caja para Age y WaitDays según asistencia y distribuciones individuales. Interpretan correctamente la fuerte concentración de WaitDays en valores bajos y la asimetría hacia valores altos; además aportan percentiles.

Por reforzar: acompañar las figuras de cantidades y tasas comprobables y diferenciar observación de explicación causal. Por ejemplo, interpretar los registros con Age cercano a cero como «consultas pediátricas obligatorias» no se desprende del archivo, que no contiene el motivo de la consulta. Del mismo modo, no consta si las citas fueron de urgencias o atención primaria. La exploración es útil, pero sus inferencias deben mantenerse dentro de lo observado.

Análisis univariado, bivariado y construcción del perfil

Valoración del criterio 2,0 sobre 5

Convención de las guías del curso: univariado = una característica frente al objetivo; bivariado = cruce simultáneo de dos características predictoras frente al objetivo. No se descuenta por la denominación académica de los gráficos, sino por el procedimiento que acreditan.

Univariado: realizado parcialmente

Dónde revisar: «Análisis Bivariado (Variables Categóricas Clave)». Las tablas normalizadas cruzan por separado SMS_received, Scholarship y Gender con no_asistio, y permiten comparar tasas de inasistencia. Los diagramas de caja comparan Age y WaitDays con la

respuesta. Son evidencias válidas de comparaciones individuales con la objetivo en la convención del curso.

Comprobación con las 110.516 filas depuradas: sin SMS hay 12.527 inasistencias en 75.035 citas (16,69 %); con SMS hay 9.784 en 35.481 (27,58 %). Esto respalda la dirección de la diferencia que describen, pero NO demuestra que enviar SMS provoque más faltas. El grupo reconoce esta cautela, lo cual se valora. Las explicaciones socioeconómicas y de transporte para Scholarship son posibles hipótesis, no hechos registrados.

Bivariado: falta el cruce de dos características

La sección titulada «Análisis Bivariado» contiene tres comparaciones separadas de una característica con no_asistio. No muestra una combinación de dos predictoras simultáneas (por ejemplo, SMS_received + Scholarship frente a no_asistio) con número de citas, número de inasistencias y tasa por combinación. Para cumplir la actividad deben construir ese cálculo, sin confundir tres gráficas individuales con un cruce conjunto.

Perfil: aún no sustentado

La «Conclusión de Negocio» se enfoca en umbrales y capacidad de la clínica, pero no presenta un perfil de citas con mayor tasa de inasistencia respaldado en el análisis combinado. Es necesario definir características concretas del perfil, contar las citas que las cumplen, calcular su tasa y compararla con el 20,19 % de inasistencia de la base depurada. No basta con enumerar factores potenciales.

Regresión logística y umbrales

Regresión logística 4,5 sobre 5

Dónde revisar: bloque «Regresion Logistica» y «Justificación del Modelo». Eligen Gender, Neighbourhood y ocho características numéricas; excluyen PatientId y AppointmentID de las predictoras. Mediante GroupShuffleSplit separan pacientes, de manera que un mismo identificador no aparezca en ambos conjuntos. Preparan columnas numéricas y categóricas dentro del flujo de trabajo (Pipeline) y entrenan LogisticRegression. La salida registra «Modelo entrenado exitosamente».

Esta es una buena práctica metodológica, aunque agrupar por paciente no era obligatorio en las guías. Precisión: GroupShuffleSplit con train_size=0,8 reparte aproximadamente 80 % de identificadores de pacientes, no garantiza 80 % exacto de citas. En la salida hay 22.080 citas de prueba (19,98 % de 110.516). La expresión «historial médico» debe evitarse: la base registra citas y algunas características del paciente, no historias clínicas.

Probabilidades y umbral 3,5 sobre 5

Dónde revisar: bloque de probabilidades y umbrales [0.50, 0.65, 0.80] y «Entregable y Conclusión de Negocio». Obtienen probabilidades para la clase 1 y observan correctamente

que al aumentar el umbral bajan las predicciones de inasistencia de 245 a 53 y finalmente a 30. La conclusión contextualiza el posible efecto de clasificar menos faltas.

Sin exigir contenidos posteriores, es posible contar los aciertos comparando las clases predichas con las respuestas reales. Los resultados que siguen se derivan de las salidas conservadas en el cuaderno, para apoyar la corrección de la interpretación:

Umbral	Predice clase 1	Aciertos	Errores	% aciertos
0,50	245	17.479	4.601	79,16 %
0,65	53	17.543	4.537	79,45 %
0,80	30	17.552	4.528	79,49 %

Con estos tres valores, los aciertos totales aumentan levemente al subir el umbral, no disminuyen. El grupo debió expresarlo explícitamente y proponer una hipótesis apoyada en esa tendencia, sin afirmar que 0,80 sea óptimo. La conclusión usa expresiones como «certeza matemática extrema» y «salas estarán llenas», que son excesivas: probabilidad estimada no equivale a certeza y predecir clase 0 no acredita ocupación real. La comparación avanzada presentada voluntariamente no se exige ni sustituye la explicación básica de aciertos.

Prioridad de mejora

Conservar la limpieza documentada y el correcto entrenamiento. Completar, a continuación, una tabla bivariada verdadera (dos características predictoras y la objetivo), verificar un perfil de riesgo y expresar el comportamiento de los umbrales mediante las predicciones y los aciertos realmente registrados. Separar resultados observados de hipótesis de negocio.

Conclusión de la evaluación

Nota propuesta: 3,6 sobre 5,0 (suma ponderada 3,575). La preparación de datos y la regresión logística son fortalezas claras. La principal limitación aparece en el recorrido analítico: el grupo interpreta relaciones individuales, pero no demuestra el cruce de dos características ni calcula un perfil final verificable de citas con mayor inasistencia.

Criterio	Nota	Aprendizaje por reforzar
Limpieza y diagnóstico	4,5	Moderar afirmaciones sobre origen de extremos; precisar significado de Handcap.
Exploración de datos	3,5	Conectar gráficas con cifras; no inferir motivos clínicos no registrados.
Univariado, bivariado y perfil	2,0	Cruzar dos predictoras frente a objetivo; contar y verificar el perfil.
Regresión logística	4,5	Mantener el entrenamiento; distinguir pacientes de número de citas en la partición.
Probabilidades y umbral	3,5	Explicar aciertos y tendencia observada; evitar hablar de certeza u ocupación.

Por qué se obtiene esta nota

El criterio de análisis y perfil representa el 25 %: se reconoce un univariado útil, pero faltan bivariado combinado y perfil; por eso allí se produce el mayor descuento. La buena ejecución técnica de regresión no compensa la ausencia del análisis solicitado. Los contenidos avanzados que aparecen en el cuaderno no se toman como exigencia ni se penalizan por su uso.

Qué deben poder explicar después de corregir

Definan un perfil mediante dos condiciones de la cita y demuestren cuántas citas lo integran, cuántas faltaron, su tasa y comparación con la tasa global. Después expliquen cómo cambian predicciones y aciertos en 0,50, 0,65 y 0,80, y qué hipótesis explorarán en una lección posterior.

Aprendizaje prioritario para reforzar en clase

Conectar análisis de variables individuales, cruces de dos características y construcción de perfiles. Separar una interpretación sustentada por datos de una conjetura causal. El trabajo demuestra fortalezas procedimentales sin que ello pruebe automáticamente dominio de la interpretación de negocio.