Retroalimentación del Grupo 8
Olist Brasil

Materia: Inteligencia de Negocios | Evaluación del Corte 2026-II

Integrantes: Sebastián Ordóñez y Miguel Yela (identificados así en el cuaderno).

Base asignada: Data 3 – Olist Brasil. Variable objetivo: entrega_tardia (Y = 1: tardía; N = 0: a tiempo).

Caso de estudio y propósito de la revisión

Pregunta del caso: ¿qué pedidos tienen mayor probabilidad de llegar después de la fecha prometida? La revisión considera el diagnóstico y la limpieza, la exploración, el análisis de características y sus combinaciones, la construcción del perfil, la regresión logística y la interpretación inicial de umbrales. Se califica únicamente lo trabajado en clase; las métricas avanzadas del cuaderno no son exigencias de este corte.

Rúbrica y valoración

Criterio	Peso	Nota / 5,00	Aporte
Limpieza y diagnóstico	20 %	4,00	0,800
Exploración de datos	15 %	4,50	0,675
Análisis univariado, bivariado y perfil	25 %	3,00	0,750
Regresión logística	25 %	4,50	1,125
Probabilidades y umbral	15 %	4,00	0,600
TOTAL	100 %		3,950

Nota propuesta: 3,95/5,00. Esta calificación valora el procedimiento, los resultados y las interpretaciones, sin exigir matrices de confusión, curvas ROC ni otras métricas no enseñadas.

Cómo se comprobaron las observaciones

Se revisaron las 73 celdas del cuaderno Sebastian_Ordonez_Miguel_Yela.ipynb, sus salidas guardadas y el archivo datos.csv suministrado para Olist. Las referencias siguientes corresponden a títulos de secciones o bloques del Colab; no a números de celdas. Se efectuaron comprobaciones independientes de cantidades y tasas históricas seleccionadas. No se presenta una ejecución completa de la sesión original del estudiante.

1. Limpieza y diagnóstico — 4,00/5,00

Dónde revisar: «3. Diagnóstico y limpieza de datos» y «4. Ingeniería de variables». Se reconoce la conversión de fechas, el registro de las decisiones, la revisión de duplicados, las reglas de consistencia, la imputación de faltantes y la corrección de seis pesos iguales a cero.

La base tiene 96.470 pedidos. Después de excluir 14 registros con aprobación sin fecha válida quedan 96.456; no se detectaron identificadores de pedido duplicados ni inconsistencias cronológicas adicionales bajo las reglas aplicadas.

Aspecto por corregir: la frase «no se elimina ninguna fila por faltantes» contradice la eliminación previa de 14 pedidos por ausencia de fecha de aprobación. Debe distinguirse entre los faltantes de las características físicas (imputados) y los de fecha (eliminados). La imputación de peso y dimensiones se efectúa antes de separar entrenamiento y prueba; para evitar que el conjunto de prueba intervenga en la preparación, las medianas destinadas al modelado deben aprenderse solo con entrenamiento. La decisión de excluir los 14 pedidos requiere justificar por qué la fecha es imprescindible para este caso.

2. Exploración de datos — 4,50/5,00

Dónde revisar: «5. Análisis univariado». Presentan conteos y proporciones de la variable objetivo, histogramas de nueve variables numéricas y frecuencias de variables categóricas. Interpretan que la entrega tardía es minoritaria y explican la distribución geográfica y temporal de los pedidos.

Resultado histórico después de limpieza	Pedidos	Porcentaje
A tiempo (0)	89.922	93,23 %
Tardíos (1)	6.534	6,77 %
Total	96.456	100,00 %

Las gráficas proporcionan un contexto útil. Conviene distinguir las observaciones de las explicaciones causales: por ejemplo, decir que la distancia «aumenta» el retraso como causa requiere evidencia adicional; lo demostrado es una asociación histórica.

3. Análisis univariado, bivariado y perfil — 3,00/5,00

Dónde revisar: «6. Análisis bivariado» y «10. Conclusión de negocio». Bajo la convención del curso, analizar una característica frente al objetivo es univariado; cruzar simultáneamente dos características predictoras frente al objetivo es bivariado. El trabajo realiza comparaciones individuales con tasas de retraso, cantidades y diferencias respecto de la tasa general. Este aporte está bien documentado, aunque el encabezado «Análisis bivariado» utiliza una convención distinta a la enseñada.

Falta una tabla que combine dos características predictoras y muestre pedidos, tardíos y tasa por combinación. La conclusión identifica un perfil candidato con destino norte/nordeste, vendedor en otro estado, determinados meses y plazo ajustado, pero no verifica el tamaño y la tasa conjunta de esas condiciones. Por ello, se reconoce el perfil interpretativo, sin considerarlo un perfil histórico completamente comprobado.

Ejemplo de comprobación independiente que podrían incorporar: al combinar «cliente y vendedor en estados distintos» con «compra en febrero o marzo», se obtienen 11.746 pedidos, 2.014 tardíos y una tasa de 17,15 %, superior a la tasa global de 6,77 %. Este cálculo ejemplifica el cruce enseñado; no estaba presentado de ese modo en el Colab.

4. Regresión logística — 4,50/5,00

Dónde revisar: «7. Preparación para el modelo», «8. Entrenar la Regresión Logística». Se definen 14 características de entrada (9 numéricas y 5 categóricas), se excluyen identificadores y la respuesta, y se transforma Y/N a 1/0. La separación estratificada conserva 77.164 pedidos para entrenamiento y 19.292 para prueba. Utilizan un flujo de trabajo (Pipeline) con transformación de variables y regresión logística, ajustado con entrenamiento.

El procedimiento central está bien resuelto. Como aspecto por mejorar, la imputación de las variables físicas ocurrió antes de la división y debe integrarse a la preparación que se aprende solo con entrenamiento. Los coeficientes pueden ayudar a describir asociaciones del modelo, pero no demuestran causalidad ni prueban que la selección de características sea óptima.

5. Probabilidades y umbral — 4,00/5,00

Dónde revisar: «9. Predicción y evaluación de umbrales (50 %, 65 %, 80 %)». Los estudiantes explican correctamente que las probabilidades individuales permanecen iguales y que el umbral modifica las clases asignadas. La distribución guardada muestra una probabilidad máxima estimada de 0,7955; por tanto, al aplicar el umbral 0,80 ningún pedido recibe la clase 1.

Umbral	Predicciones de clase 1	Observación
0,50	27	Hay pocos pedidos marcados tardíos.
0,65	3	Disminuye aún más la clase 1.
0,80	0	Todos quedan clasificados como 0.

Inconsistencia a corregir: el código y su tabla reportan 27 pedidos marcados tardíos con umbral 0,50, mientras que los párrafos explicativos posteriores indican 29. Debe utilizarse la cifra de la salida ejecutada o justificar cualquier nueva ejecución. El porcentaje general de aciertos, cercano a 93,2 %, no permite concluir por sí solo que el

modelo identifique satisfactoriamente los retrasos. Para este corte basta con interpretar el número de clasificaciones y los aciertos generales; las medidas avanzadas presentadas son trabajo adicional, no requisito de la rúbrica.

Prioridad de mejora

Conserven la preparación y entrenamiento que funcionan. Corrijan primero la discrepancia 27/29 y la explicación de los faltantes; después presenten al menos un cruce real de dos características frente a entrega_tardia; por último, definan un perfil con filtros, cantidad de pedidos, número de tardíos y tasa, comparándola con la global. Al concluir los umbrales, formulen una hipótesis de exploración posterior sin afirmar que ya se ha encontrado un umbral definitivo.

Conclusión de la evaluación

La calificación propuesta es 3,95/5,00. El grupo demuestra buenos resultados en exploración de datos, preparación y entrenamiento de regresión logística, y comprende cómo el umbral cambia las clasificaciones. La mayor dificultad es pasar de tasas por características aisladas a un cruce de dos características y a un perfil históricamente verificable. También debe corregir inconsistencias textuales y evitar preparar los datos de prueba con medianas calculadas antes de la separación.

Aprendizaje prioritario para reforzar en clase: establecer una secuencia comprobable característica → tasa por grupo → combinación de dos características → perfil → conclusión de negocio; y diferenciar los resultados numéricos guardados de las interpretaciones escritas. La observación es específica de esta entrega y no atribuye automáticamente una falta de comprensión conceptual.