Retroalimentación del grupo 9
Kickstarter – Data 4

Materia: Inteligencia de Negocios | Evaluación II Corte 2026-II

Docente: Julio Ricardo Martínez Montezuma

Integrantes: Yulieth Rossana Paz Fernández y Kevin Andrés Sánchez Chamorro

Archivo revisado: Parcial_de_Evaluación_Modelos_de_Clasificación.ipynb | Datos: datos.csv

Caso de estudio y propósito

Pregunta de negocio: ¿qué perfil de proyectos de Kickstarter presenta mayor probabilidad de éxito al momento de su lanzamiento? La variable objetivo exito se codifica como Y = 1 (campaña exitosa) y N = 0 (campaña fallida). Se examina el trabajo real presentado en el cuaderno y se califica únicamente lo abordado en clase: limpieza, exploración, análisis univariado y bivariado con perfil, regresión logística y observación de probabilidades y umbrales.

Rúbrica y valoración

Criterio	Peso	Nota / 5,00	Aporte
Limpieza y diagnóstico	20 %	3,50	0,700
Exploración de datos	15 %	4,50	0,675
Análisis univariado, bivariado y perfil	25 %	4,00	1,000
Regresión logística	25 %	4,50	1,125
Probabilidades y umbral	15 %	2,00	0,300
TOTAL	100 %		3,800

Nota final propuesta: 3,80 / 5,00. El puntaje reconoce el análisis bivariado y la construcción de perfiles realmente realizados; la mayor actividad pendiente está en la comparación de umbrales y aciertos. La nota puede revisarse ante evidencia adicional verificable.

Método de comprobación

Se inspeccionaron las 83 celdas del cuaderno, incluyendo el código y las salidas de texto guardadas, y se contrastaron estructura y frecuencias generales con el archivo Kickstarter suministrado (331.675 filas y 10 columnas). No se interpreta el resultado guardado como si se hubiera ejecutado íntegramente de nuevo la sesión de Google Colab. Las referencias se dan por secciones y títulos del cuaderno.

1. Limpieza y diagnóstico – 3,50 / 5,00

Dónde revisar: «3.1 Revisión inicial», «Hallazgos», «4. Análisis exploratorio» y decisiones previas a la parte II. Identifican tres valores ausentes en name y 210 valores anómalos N,0" en country, que convierten a «Desconocido» sin inventar un país. Justifican excluir identificadores y columnas no usadas. Es un diagnóstico pertinente.

La preparación elimina tempranamente ID, name, category, currency y las fechas. La exclusión de identificadores está justificada, pero no se documenta una auditoría suficiente de metas nulas, imposibles o de la coherencia de las fechas antes de descartarlas. Especial atención a goal: el cuaderno reconoce que está expresada en monedas diferentes; aun así crea rangos numéricos comunes (≤1K, 1K–5K, etc.). La predominancia de USD no vuelve comparables las demás monedas. Esto afecta las conclusiones por rangos y es el principal límite de la limpieza analítica; no se penaliza la ausencia de métodos avanzados no enseñados.

2. Exploración de datos – 4,50 / 5,00

Dónde revisar: «4. Análisis exploratorio», gráficas de categorías y país, describe() e histograma de goal. El cuaderno estudia frecuencias de main_category, currency y country, examina el sesgo de goal y distingue la mediana de la media. Interpreta correctamente la composición general de la base y reconoce la presencia de valores extremos.

Debe evitarse afirmar que country y currency son casi la misma información basándose solo en predominancias parecidas, y las metas visualizadas en monedas locales no deben leerse como cantidades homogéneas. Son reservas interpretativas concretas, sin desmerecer la exploración desarrollada.

3. Análisis univariado, bivariado y perfil – 4,00 / 5,00

Dónde revisar: «4.2 Análisis univariado», «4.3 Análisis bivariado» y «Conclusiones». A diferencia de otros grupos, aquí sí hay evidencia del cruce de dos características predictoras frente a exito_bin mediante groupby sobre pares y cálculo de la media del objetivo. Se estudian main_category + grupos_goal, grupos_pais + grupos_goal y

main_category + grupos_pais. El trabajo cumple sustancialmente la secuencia trabajada en clase.

En univariado presentan tasas por rangos de meta, categoría y país; identifican categorías con mayor y menor frecuencia de éxito. En las conclusiones proponen un perfil de mayor éxito (metas bajas, Dance/Theater/Comics, US/GB) y otro de mayor riesgo. Estas son hipótesis descriptivas fundamentadas en cruces, no garantizan resultados futuros.

Para fortalecer el perfil, conviene identificar en una tabla el total y los proyectos exitosos para la combinación seleccionada, además de su tasa, y contrastarla con la tasa global de 40,39 %. Los gráficos de medias no muestran el tamaño de cada combinación, por lo que algunas tasas elevadas podrían corresponder a pocos proyectos. La mezcla de monedas también puede alterar el perfil según grupos_goal. Se reconoce el análisis realizado; no se califica como ausente el bivariado.

4. Regresión logística – 4,50 / 5,00

Dónde revisar: «PARTE II. REGRESIÓN LOGÍSTICA», pasos 3 a 5. Transforman Y/N a 1/0 y separan 265.340 proyectos para entrenamiento y 66.335 para prueba (80/20), con estratificación y semilla reproducible. Seleccionan main_category, grupos_pais y grupos_goal, y ajustan la codificación de categorías solo con entrenamiento, aplicándola después a prueba. El codificador produce 23 columnas y la regresión se ajusta sin advertencias de convergencia según la salida guardada.

Además, muestran la probabilidad de un proyecto construido manualmente (Music, US, 1K–5K: 0,5602) y su clase con umbral 0,50. Esta es una aplicación correcta del procedimiento enseñado. Como mejora: explicar que el modelo hereda las limitaciones del rango goal construido con monedas diferentes y que la convergencia del entrenamiento no demuestra por sí sola calidad predictiva.

5. Probabilidades y umbral – 2,00 / 5,00

Dónde revisar: «Paso 5. Predecir con el modelo entrenado», apartados 5.1 a 5.4. Distinguen probabilidad de clase, aplican correctamente el umbral de 0,50 y reportan 49.766 proyectos predichos como clase 0 y 16.569 como clase 1, sobre 66.335 proyectos de prueba. Explican adecuadamente que cambiar el umbral alteraría las clases, no las probabilidades estimadas.

Sin embargo, el cuaderno se detiene en 0,50: NO compara varios umbrales ni cuenta aciertos y errores según cada umbral, ejercicios que sí forman parte de nuestra primera guía. Tampoco formula una hipótesis fundamentada sobre la dirección de exploración del umbral. El propio texto indica que la comparación con respuestas reales queda para

otra etapa. Esta ausencia concreta explica el descuento; no se requieren matrices de confusión ni indicadores avanzados.

Conclusión de la evaluación

Nota propuesta: 3,80 / 5,00. El grupo demuestra un buen manejo exploratorio, desarrolla auténticos cruces bivariados y elabora perfiles candidatos. Asimismo, prepara y entrena correctamente el modelo y obtiene probabilidades para proyectos nuevos. El componente menos logrado es la comparación de umbrales y de aciertos, solicitada en el alcance de esta evaluación, que no aparece desarrollada. La mezcla de monedas al formar rangos de metas limita la solidez de algunas interpretaciones.

Aprendizajes por reforzar

Primero, asegurar que las variables numéricas sean comparables antes de agruparlas; segundo, respaldar el perfil elegido con cantidades, tasas y comparación frente al total; tercero, comparar al menos varios umbrales y describir el cambio en las clases y en los aciertos, sin afirmar que se ha encontrado el umbral óptimo. Este cierre permite iniciar la siguiente clase con una hipótesis comprobable, dentro del nivel enseñado.