Retroalimentación del grupo 10
Kickstarter – Data 4

Materia: Inteligencia de Negocios | Evaluación II Corte 2026-II

Docente: Julio Ricardo Martínez Montezuma

Integrante asignado al Grupo 10: Jeyler Antonio Martínez Grueso (nombre no diligenciado en el cuaderno)

Archivo revisado: Taller_Kickstarter_Caso04.ipynb | Datos de referencia: datos.csv

Caso de estudio y propósito

Pregunta de negocio: al comenzar una campaña de Kickstarter, ¿qué probabilidad tiene de finalizar con éxito? La variable exito distingue Y = 1 (exitosa) y N = 0 (fallida). El ejercicio debe usar características disponibles al lanzamiento, reconocer asociaciones en los datos y construir un perfil histórico verificable.

Rúbrica y valoración

Criterio	Peso	Nota / 5,00	Aporte
Limpieza y diagnóstico	20 %	4,00	0,800
Exploración de datos	15 %	4,50	0,675
Análisis univariado, bivariado y perfil	25 %	2,00	0,500
Regresión logística	25 %	4,50	1,125
Probabilidades y umbral	15 %	4,50	0,675
TOTAL	100 %		3,78

Nota final propuesta: 3,78 / 5,00. El cuaderno evidencia buena preparación, entrenamiento y comparación de umbrales; el principal descuento corresponde a la ausencia de un cruce de dos características predictoras y de un perfil estadístico con recuentos verificables.

Método de comprobación

Se revisaron las 28 celdas del cuaderno, su código, explicaciones y salidas almacenadas. Se distinguió lo efectivamente ejecutado de las afirmaciones escritas y se aplicó exclusivamente la rúbrica del curso. En la portada permanece el campo

«Nombres del/los estudiante(s): completar antes de subir»; la atribución al Grupo 10 procede de la asignación de clase, no de una firma en el archivo.

1. Limpieza y diagnóstico – 4,00 / 5,00

Dónde revisar: secciones «1. Diagnóstico y Limpieza» y celdas de preparación. Reporta 331.675 filas y 10 columnas iniciales; identifica tres ausencias en name, 14 monedas y 210 registros con country = «N,0"». Convierte Y/N en 1/0, transforma fechas, deriva duración, recodifica el país anómalo como Unknown y documenta conversión monetaria aproximada a USD. Las salidas muestran 92 filas descartadas por duración inferior a un día y 28 por goal = 100.000.000, para conservar 331.555 observaciones.

Observaciones: se afirma que existen 29 metas exactamente iguales a 100.000.000, pero el filtro ejecutado elimina 28 en el conjunto ya depurado; hay que aclarar la diferencia entre el recuento previo y el posterior al filtro de duración. Tampoco está demostrado que todas esas metas sean valores erróneos, ni que una duración menor a un día implique siempre un error de carga. Las tasas de cambio fijas son una aproximación explícita, no equivalencias históricas exactas; el análisis debe reconocer esa limitación.

2. Exploración de datos – 4,50 / 5,00

Dónde revisar: «2. Exploración de Datos (EDA)» y gráficos almacenados. Se examinan frecuencias de la variable objetivo, metas monetarias, categorías principales, países, duración y año de lanzamiento. Se interpreta la distribución inicial de alrededor del 59,61 % de campañas fallidas y 40,39 % exitosas tras la limpieza. Los histogramas y diagramas de caja permiten reconocer asimetría de la meta y diferencias entre grupos.

Fortaleza: vincula gráficas con explicaciones escritas y contrasta tasas de éxito por categoría y año con la tasa general. Por mejorar: expresiones como «confirma que aporta señal» o explicaciones sobre saturación de la plataforma deben presentarse como asociaciones o hipótesis, no como relaciones causales comprobadas.

3. Análisis univariado, bivariado y perfil – 2,00 / 5,00

Dónde revisar: gráficos de «tasa de éxito por categoría principal», metas y duración según resultado, «tasa de éxito por año» y lecturas interpretativas. Con la nomenclatura de este curso, sí desarrolla análisis de una característica predictora frente a exito: categoría, año, meta y duración, con comparaciones visuales y observaciones.

Sin embargo, no se presenta un análisis bivariado en el sentido solicitado en clase: combinar DOS características predictoras y calcular para cada combinación cuántos proyectos hay, cuántos fueron exitosos y su tasa de éxito. Los gráficos de meta según resultado o duración según resultado no reemplazan ese cruce. Tampoco hay un perfil

histórico definido por dos atributos y sustentado con esos tres datos verificables. La sección final describe oportunidades y decisiones del inversor, pero no constituye el perfil pedido.

Para completar el criterio: cruzar, por ejemplo, main_category y un rango de goal_usd con exito_bin; mostrar total de campañas, cantidad exitosa y porcentaje para cada combinación; elegir una combinación con soporte suficiente y compararla con la tasa general. Mantener las reservas de la conversión monetaria aproximada.

4. Regresión logística – 4,50 / 5,00

Dónde revisar: «3. Regresión Logística». Construye X con siete características disponibles al lanzamiento y y = exito_bin; separa 265.244 registros para entrenamiento y 66.311 para prueba (80/20, estratificado). Aplica codificación categórica y escalado dentro de un flujo de trabajo (Pipeline), ajustado al entrenamiento, y ejecuta correctamente LogisticRegression. La salida confirma «Modelo entrenado».

El cuaderno obtiene probabilidades mediante predict_proba y registra 0,651 de proporción general de aciertos al umbral 0,50. Es adecuado excluir información conocida solo al cierre de la campaña. Como mejora, se recomienda justificar con brevedad cada predictor y diferenciar que una tasa de aciertos del 65,13 % no significa que el modelo acierte por igual en proyectos exitosos y fallidos. No se exige la interpretación de indicadores adicionales no enseñados.

5. Probabilidades y umbral – 4,50 / 5,00

Dónde revisar: «4. Evaluación de Umbrales (50%, 65%, 80%)». Compara explícitamente los tres puntos de corte sobre las mismas probabilidades. Según la tabla guardada: a 0,50 se clasifican 18.527 campañas como exitosas y la proporción de aciertos es 65,1325 %; a 0,65, 4.541 y 62,3094 %; a 0,80, 304 y 59,8920 %. Interpreta correctamente que elevar el umbral reduce los casos predichos como éxito y, en este ejemplo, también disminuyen los aciertos generales.

Fortaleza: vincula el umbral con una decisión de negocio y reconoce el costo de descartar campañas prometedoras. Para una lectura perfectamente alineada con la guía del curso, convendría acompañar cada porcentaje con su cantidad exacta de aciertos y errores sobre las 66.311 observaciones de prueba; la tabla presenta porcentajes e indicadores adicionales, pero no esos recuentos simples. No se descuentan procedimientos avanzados por exceder el programa.

Conclusión de la evaluación

Nota propuesta: 3,78 / 5,00. El grupo presenta un cuaderno organizado, con tratamiento explícito de las monedas, exploración variada, regresión logística correctamente

entrenada y comparación pertinente de umbrales. La principal debilidad corresponde a uno de los objetivos centrales del corte: pasar de asociaciones individuales a una combinación de dos variables que sustente un perfil concreto y verificable de campañas con mayor éxito histórico. Las decisiones de limpieza requieren además mayor prudencia al catalogar registros como errores.

Aprendizajes por reforzar

Primero, construir cruces de dos atributos con total, éxitos y porcentaje para cada combinación; segundo, formular el perfil a partir de esas cantidades y contrastarlo con la tasa general; tercero, diferenciar una hipótesis de una irregularidad demostrada al depurar; cuarto, reportar los aciertos y errores simples por umbral. Se reconoce la claridad de la explicación de probabilidades y sus implicaciones en el negocio.