Retroalimentación del grupo 11
Titanic – Data 5

Materia: Inteligencia de Negocios | Evaluación II Corte 2026-II

Docente: Julio Ricardo Martínez Montezuma

Integrantes identificados: Samuel Fernández Díaz y Víctor Zemanate

Archivo revisado: Parcial_corte2_samuel_fernandez_victor_zemanate.ipynb | Base: datos.csv

Caso de estudio y propósito

Pregunta del caso: ¿cómo se relacionan las características de los pasajeros con su probabilidad de supervivencia? Cada fila representa un pasajero; sobrevivio registra Y = sobrevivió (1) y N = no sobrevivió (0). El cuaderno contiene 53 celdas y salidas de ejecución guardadas. La base utilizada presenta 1.309 pasajeros y 12 columnas.

Rúbrica y valoración

Criterio	Peso	Nota / 5,00	Aporte
Limpieza y diagnóstico	20 %	4,50	0,900
Exploración de datos	15 %	4,50	0,675
Análisis univariado, bivariado y perfil	25 %	2,25	0,563
Regresión logística	25 %	4,75	1,188
Probabilidades y umbral	15 %	4,75	0,713
TOTAL	**100 %**		**4,04**

Calificación propuesta: 4,04 / 5,00. Se reconoce la solidez del diagnóstico, la división entrenamiento/prueba, la ejecución del modelo y la lectura de umbrales. El descuento principal responde a la ausencia de un cruce simultáneo de dos características predictoras y de un perfil histórico plenamente cuantificado.

Alcance y comprobación

Se verificaron código, explicaciones y resultados guardados en el Colab. Las cifras que siguen proceden de esas salidas; no se presenta una reejecución independiente. Conforme a lo enseñado, el análisis univariado se entiende como una característica predictora frente a la respuesta y el bivariado como dos predictoras combinadas frente a

la respuesta. Las métricas avanzadas que el equipo presenta son aportes complementarios, no requisitos de calificación.

1. Limpieza y diagnóstico – 4,50 / 5,00

Evidencia: celdas 8–13. Se comprueban dimensiones, tipos, ausencia de duplicados completos (0) y faltantes: cabin 1.014 (77,46 %), home.dest 564 (43,09 %), age 263 (20,09 %), embarked 2 y fare 1. La variable objetivo se normaliza y convierte explícitamente a N = 0, Y = 1; sus clases quedan 809 y 500 registros, respectivamente.

Las decisiones se explican razonablemente: age y fare con mediana, embarked con categoría frecuente y cabin transformada en indicador de dato registrado. Se propone excluir home.dest por cantidad de ausencias y cardinalidad. Las imputaciones se aprenden más adelante solo con entrenamiento, una buena práctica. Como mejora, no debe suponerse sin evidencia que cabin ausente equivale a que nunca se asignó cabina; el indicador mide registro disponible, no la condición real del pasajero.

2. Exploración de datos – 4,50 / 5,00

Evidencia: celdas 14–24. Se muestran distribución de la respuesta y porcentajes: 809 pasajeros no sobrevivieron (61,80 %) y 500 sobrevivieron (38,20 %). También se estudian estadísticos de edad y tarifa; distribuciones de sexo, clase, puerto, familiares, histogramas y tasas históricas por categoría.

Los ejemplos son pertinentes y las explicaciones generalmente distinguen asociación de causalidad. La tarifa muestra valores extremos y asimetría que merecen cautela al interpretar promedios. En la celda 22 aparece además un mensaje de error de visualización asociado a una salida gráfica; las tablas numéricas sí constan en el cuaderno. Se recomienda comprobar que todas las figuras queden reproducibles y sin errores en la versión entregada.

3. Análisis univariado, bivariado y perfil – 2,25 / 5,00

Evidencia: celdas 21–24. Hay buen análisis de una característica predictora por vez: entre 466 mujeres, 339 sobrevivieron (72,75 %); entre 843 hombres, 161 (19,10 %). Por clase, sobrevivieron 200 de 323 pasajeros de primera (61,92 %), 119 de 277 de segunda (42,96 %) y 181 de 709 de tercera (25,53 %). También se examinan puerto, sibsp y parch.

No obstante, estos cálculos comparan cada característica por separado con la variable objetivo. No aparece una tabla que combine, por ejemplo, sex + pclass y calcule para cada combinación el total, los sobrevivientes y la tasa. Por esa razón no se acredita el componente bivariado según la convención del curso.

Tampoco queda construido un perfil histórico final con dos condiciones simultáneas y sus tres cifras verificables: número de pasajeros, cantidad de sobrevivientes y porcentaje de supervivencia. Una propuesta de mejora sería definir «mujeres de primera clase» y calcular sobre la base real cuántas cumplen ambas condiciones, cuántas sobrevivieron y cuál fue la tasa, comparándola con el 38,20 % general. No deben inventarse esos conteos: deben obtenerse mediante código y mostrarse.

4. Regresión logística – 4,75 / 5,00

Evidencia: celdas 25–36. El trabajo crea X con 11 características y y = sobrevivio_bin. Deriva tamaño de familia, indicador de viajar solo, cabina registrada y título a partir del nombre; excluye el nombre original y otros campos no elegidos. Divide el conjunto de manera estratificada en entrenamiento (1.047; 80 %) y prueba (262; 20 %).

El flujo de trabajo (Pipeline) realiza imputación numérica y categórica, estandarización, codificación One-Hot y ajuste de LogisticRegression. Las salidas confirman entrenamiento finalizado, clases [0, 1] y uso exclusivo del conjunto de entrenamiento para ajustar las transformaciones. Como matiz, la selección de títulos frecuentes se calcula antes de separar los datos; sería más cuidadoso aprender también ese criterio solo en entrenamiento, aunque no se penaliza como exigencia adicional del corte.

5. Probabilidades y umbral – 4,75 / 5,00

Evidencia: celdas 37–51. Se obtienen probabilidades con predict_proba sobre los 262 pasajeros de prueba y se aplican las reglas 0,50, 0,65 y 0,80. El grupo interpreta acertadamente que elevar el umbral reduce las predicciones de supervivencia (99 → 74 → 49) sin alterar las probabilidades calculadas. Los aciertos simples pueden recuperarse de las salidas del propio cuaderno:

Umbral	Predichos como 1	Aciertos / 262	% de aciertos
0,50	99	221	84,35 %
0,65	74	214	81,68 %
0,80	**49**	**203**	**77,48 %**

Se interpretan de forma coherente el descenso de aciertos y el costo de exigir probabilidades mayores. También se demuestra un pasajero de prueba con probabilidad 0,537, que cambia de clase al elevar el umbral, y un caso manual con probabilidad 0,105. Las matrices de confusión y demás métricas no se exigían; no reciben bonificación automática. El trabajo sí cumple lo enseñado: probabilidades, reglas de decisión y conteo verificable de aciertos.

Conclusión pedagógica y recomendaciones

Samuel y Víctor presentan un cuaderno claro, ordenado y técnicamente consistente en el proceso de regresión logística. Diagnostican faltantes, razonan el tratamiento de variables, reservan el conjunto de prueba, entrenan correctamente y explican con ejemplos cómo actúan los umbrales. Es especialmente positivo que no confundan elevar el umbral con modificar la probabilidad calculada.

Para mejorar el cumplimiento del taller, deben completar el análisis combinado de dos características predictoras y convertirlo en un perfil histórico concreto con total de casos, sobrevivientes y tasa. Además, conviene verificar que todas las salidas gráficas sean reproducibles y fundamentar cuidadosamente las explicaciones históricas. La calificación propuesta, basada exclusivamente en la rúbrica, es 4,04 / 5,00.